קומפילציה

שלבי קומפילציה

- ***מנתח לקסיקלי (lexer – lexical analyzer)*** – מפריד את הקלט ליחידות בסיסיות הנקראות אסימונים – tokens.
לדוגמא: **position := initial + rate * 60**
  - position הוא האסימון, הערך הסמנטי שלו (לקסיקלי) הוא השם שלו – position וסוג האסימון (המזהה) הוא ID.
  - האסימון הבא יהיה ':=', לאסימון זה אין ערך סמנטי.
  - initial הוא אסימון מסוג ID.
  - '+' הוא אסימון מסוג ADDOP.
  - rate הוא אסימון מסוג ID.
  - ' * ' הוא אסימון מסוג MULOP.
  - '60' הוא אסימון מסוג NUM.
  - ' ; ' הוא אסימון מסוג semicolon.

מכך נובע שהביטוי **position := initial + rate * 60** מפורק ע"י ה-lexer ל – ***ID := ID ADDOP ID MULOP NUM SEMICOLON.***
האסימונים הם בעצם ה-terminals של שפת התכנות, כמו כן מילים שמורה של אותה השפה נכנסים גם תחת הקטגוריה הזו.

- ***Parser:*** בונה עץ גזירה (parse tree), עבור קלט נתון (הקלט הוא סדרה של אסימונים).
דוגמאות לחוקי גזירה בשפת תכנות:
  - STMT → while (EXP) STMT
  - STMT → EXP semicolon
  - STMT → if (EXP) STMT else STMT
  - STMT → id := EXP semicolon
  - EXP → EXP addop
  - EXP → num
  - EXP → id

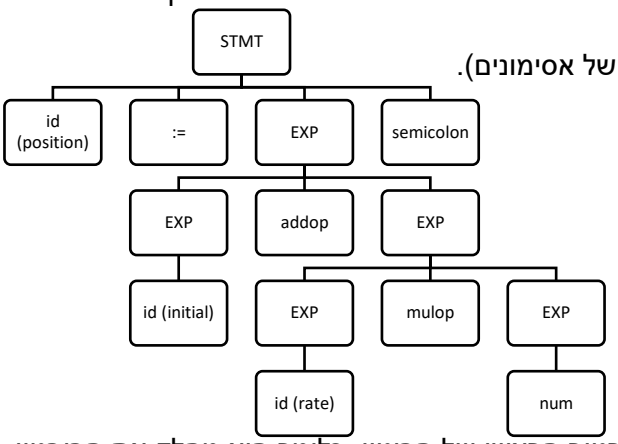

- מתייחסים לאופרטוא החלש יותר (במקרה הזה הוא '+'), הוא האופרטור הראשי של הביטוי. כלומר הוא מחלק את הביבטוי שמימין להשמה ל-2 חלקים: (EXP mulop EXP) **addop** (EXP).

התוצר של ה-parsing הוא לעיתים קרובות AST (abstract syntax tree), לא כל קומפיילר מייצר את המבנה נתונים הזה.
במקרה הזה ה-AST הוא עץ השמה.
דוגמא:

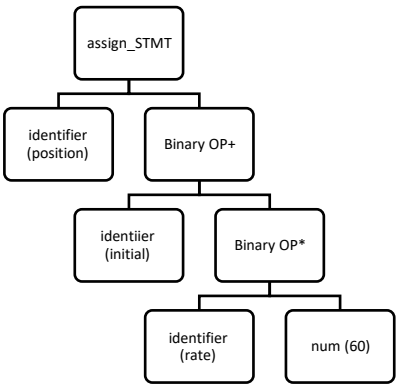

- ***טבלת סמלים (symbol table)*** – הקומפיילר שומר את המשתנים של התוכנית בטבלת משתנים. כאשר בטבלה הזו שמור מידע נוסף על כל משתנה (טיפוס, static, final ועוד..). את הערך ל המשתנה לא ומרים בטבלה, היות והוא יכול להשתנות. לעומת זאת ה-interpreter כן שומר את ערכי המשתנים בטבלה.

- ***מנתח סמנטי*** – בודק את תקינות המשמעויות של הביטויים לפי כללי שפת התכנות.
למשל: "האם כל משתנה שמשתמשים בו הוגדר בדיוק פעם אחת" – זוהי בדיקה סמנטית היות ואם אותו משתנה יוגדר יותר מפעם אחת זאת טעות סמנטית (במשמעות הביטוי) ולא טעות דקדוקית. ככלל כל טכות שמפרה את כללי שפת התכנות, שהיא לא טעות

קומפילציה

דקדוקית, זאת טעות סמנטית. ("int I = "hello – טעות סמנית, כל כללי הדקדוק כאן תקינים אך המשמעות לא).
חלק מהבדיקות שנעשות בשלב זה, הן בדיקות typechecker – בדיקות טיפוסי המשתנים בהתאם לביטוי בו הם נמצאים.

- ***ייצור קוד ביניים –*** intermediate code IR (intermediate representation). ייצור קוד פשוט יותר מקוד המקור (הקוד בשפת התכנות). קוד ביניים צריך להיות בעל תכונה – three address code, כלומר שיש לכל היותר אופרטור אחד בנוסף לאופרטור ההשמה (ביטוי פשוט). כמו a = b + c.

למה זה טוב?

- מודולריות – חלוקה ל – frontend / backend.
- מאפשר הרצה של אלגוריתמי אופטימיזציה על הקוד.
- מקל על התרגום לשפת אסמבלי.

לאחר השלב הזה מתבצעת אופטימיזציה של קוד הביניים (יכולות להיות שורות קוד שהמיקום שלהם ביחס לקוד מקורה יהיה שונה, על מנת לייעל את הריצה), כדי שהתוכנית תרוץ בצורה יעילה יותר. לאחר מכן מייצר את קוד המטרה (בשפת כונה שאפשר להריץ על המעבד) ומתבצעת אופטימיזציה שלו.

תיאור ויזואלי של התהליך:

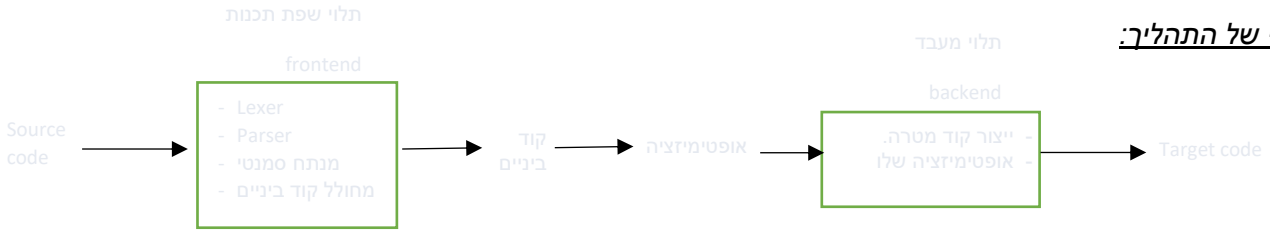

- נניח שיש ברשותינו קומפיילר : c → mips
ואנחנו מעוניינים בקומפיילר : java → mips. לשם כך יש לשכתב רק את ה-frontend.

Flex – כלי לייצור מנתח לקסיקלי

אנחנו רוצים להגדיר ש-175 יהיה בעל מזהה NUM, bar יהיה בעל מזהה ID, "hello" יהיה בעל מזהה STRING.

נכין קובץ mylex.lex שיכיל את הפונקציה שתדפיס את נתונים בהתאם למזהה שלהם (לצורך העיניין פונקציית ה-main). נכתוב את הפקודות הבאות ב-cmd:

1. Flex.exe mylex.lex
נוצר קובץ lexyy.c הכולל את הפונ' yylex.
2. נקמפל את הקובץ lexyy.c בעזרת קומפיילר של שפת C – gcc, ויתקבל קובץ הרצה – myprog.exe.
3. Myprog.exe mytest.txt – הקובץ mytest.txt הוא קובץ הקלט אשר מכיל את השורה: "hello" bar 175.
לכן יודפס למסך:
NUM: 175
ID: bar
String: "hello"

ממשק ל-yylex

Yylex מחזירה מספר המייצר את סוג האסימון הנוכחי בקלט. את הערך הסמנטי של האסימון היא כותבת למשתנה הגלובלי yylval (משתנה של bison).

- Yylex – תמיד מחפשת את הרישא הארוכה ביותר של יתרת הקלט המתאימה לאחד הביטויים הרגולריים. במקרה שהרישא מתאימה ליותר מביטוי רגולרי אחד, היא תבחר את הביטוי שרשום קודם. במקרה ששני ביטויים רגולריים מתאימים לאותה הרישא

קומפילציה

הארוכה ביותר, אז יתבצע הביטויי הרגולרי שרשום קודם בפונ' yylex, וה-action שלו יתבצע. מהסיבה הזו הביטוי הרגולרי בשורה 39 בקוד הוא האחרון, כי נקודה מתאימה לכל תו חוץ מירידת שורה.

- %% - תוחם קטע קוד עבור ה-flex, שמגדיר את הדקדוק (rules). החוקים בדקדוק נמצאים בפונקציה yylex. במקרה הזה הפרדה בין סוגי החוקים מתבצעת ע"י רווח, כלומר bar17 יחשב כ-ID, למרות שיש בו מספר.
- קטע קוד ב-C שכתוב אחרי הבלוק של החוקים, יוצר בקובץ lexyy.c אחרי הפונ' yylex. כמו כן קטע קוד שכתוב לפני יוצב לפני.
- Ywrap – פונ' שעל המתכנת לכתוב כי להורות ל-flex שיש להמשיך לקרוא קלט ממקום אחר. הקיראה לפונקציה זו מתבצעם בסוף פונקציית yylex.
- Ytext – משתנה של yylex אשר מכיל את הקלט הנוכחי, ולעומתו בודקים את הביטויים הרגולריים.
- Yyin – קובץ הקלט של yylex, וקובץ הפלט הוא yyout בתור ברירת מחדל.

קטע קוד:

```
1   %{
2
3   #define NUM 300
4   #define ID 301
5   #define STRING 302
6
7   union {
8     int ival;
9     char name [30];
10    char str [30];
11  } yylval;
12
13  #include <string.h>
14
15  extern int atoi (const char *);
16  %}
17
18  %option noyywrap
19
20  /* exclusive start condition -- deals with C++ style comments */
21  %x COMMENT
22
23  %%
24
25  [0-9]+    { yylval.ival = atoi (yytext); return NUM; }
26
27  [a-zA-Z][a-zA-Z0-9]*        { strcpy (yylval.name, yytext); return ID; }
28
29  \"([^\\"\n]|\\.)*\" { strcpy (yylval.str, yytext); return STRING; }
30
31  [\n\t ]+  /* skip white space */
32
33  "//"        { BEGIN (COMMENT); }
34
35  <COMMENT>.+ /* skip comment */
36  <COMMENT>\n {  /* end of comment --> resume normal processing */
37                 BEGIN (0); }
38
39  .           { fprintf (stderr, "unrecognized token %c\n", yytext[0]); }
40
41  %%
42
43  main (int argc, char **argv)
44  {
45     int token;
46
47     if (argc != 2) {
48        fprintf(stderr, "Usage: mylex <input file name>\n", argv [0]);
49        exit (1);
50     }
51
52     yyin = fopen (argv[1], "r");
53
54     while ((token = yylex ()) != 0)
55       switch (token) {
56       case NUM: printf("NUMBER : %d\n", yylval.ival);
57                 break;
58           case ID:     printf ("ID  : %s\n", yylval.name);
59                 break;
60       case STRING: printf ("STRING: %s\n", yylval.str);
61                 break;
62           default:     fprintf (stderr, "error ... \n"); exit (1);
63       }
64     fclose (yyin);
65     exit (0);
66  }
67
```

קומפילציה

- כלל ברירת מחדל לביטויים הרגולריים : {echo;} \n|.
  כלל זה לא צריך לכתוב, הוא מתקיים לבד במקרה ואף ביטוי רגולרי לא מתאים לקלט.

Start conditions

הרעיון פה הוא להפריד את הביטויים הרגוליים לסטים, כדי שנוכל לשלוט באילו ביטויים רגולריים להשתמש במקרים שונים. ניתן לראות בקוד שהחל משורה 33, רק הביטויים הרגולריים של SC comment פעילים, כלומר שאר הביטויים הרגולריים לא ישפיעו על העבודה.

לדוגמא:

a?b
<foo>[0-9]+
<foo>abc*
<bar>aaaa
<bar>.*

בכל רגע נתון yylex נמצאת ב- start condition מסויים, כל מה שנמצא בתגיות מציין את ה-start condition, ומה שמימין לתגיות אלו הם הביטויים הרגולריים.

כאשר לא מצויין start condition מסויים, yylex נמצאת ב-<initial> : start condition, בדוגמא הנ"ל a?b זה ה-initial. כדי לעבור לביטויים הרגולריים של initial ניתן לכתוב BEGIN(initial) או BEGIN(0).

כדי לעבור ל-start condition כלשהו כותבים begin(foo).

- כשנמצאים ב –exclusive start condition (מוכרז עם x%), אז רק הכללים שלו פעילים. בקוד בשורה 21 אפשר לראות שמוגדר SC עבור הערות – comment.
  כשנמצאים ב – non-exclusive start condition , אז פעילים הכללים שלו וגם הכללים של initial. את ה-SC האלו ניתן להגדיר בעזרת S%.
  ניתן לראות בקוד שבשורה 33 עוברים ל-BEGIN(COMMENT) ובשורות 35,36 משתמשים ב-SC הזה. בקובץ הקלט מה שיגרום לקוד לעבור ל-SC של comment זה \\ שמוגדר כביטוי רגולרי של "\\".

דוגמא להרצת אלגוריתם של כלי דמוי flex

1. המר את הביטויים הרגוליים לאוטומט סופי לא דטרמיניסטי.
2. מזל את האוטומטים לאוטומט אחד גדול
3. המר את האוטומט הגדול לאוטומט סופי דטרמיניסטי. (yylex מסלמצת את האוטומט).

דוגמא: אוטומט לא דטרמיניסטי ← אוטומט דטרמיניסטי

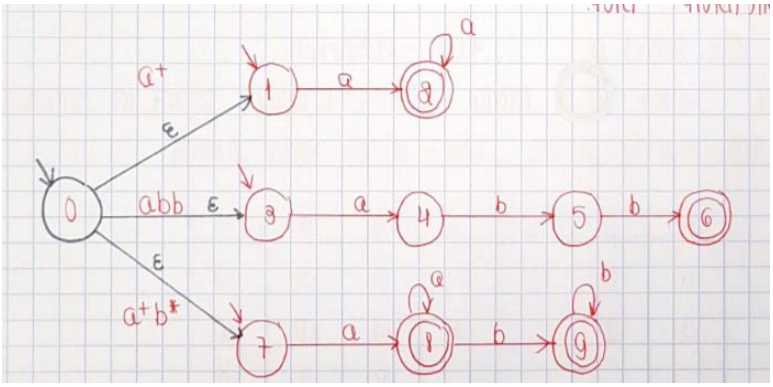

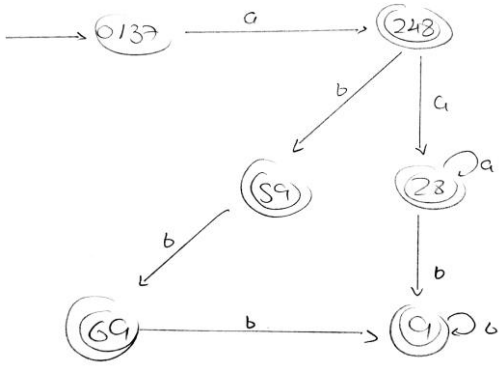

קומפילציה

עבור המחרוזת abbbaa, ההתאמה הכי ארוכה תהיה עבור האוטומט התחתון של *a+b, למרות שתהיה התאמה גם לשאר האוטומטים אבל ההתאמות יהיו קצרות יותר. בעצם כשהאוטומט יגיע למצב מת הוא ידע שהוא מצא את התאמה הכי ארוכה במצב שממנו הוא הגיע למצב המת. המחרוזת הנ"ל אחרי ה-b האחרון האוטומט יגיע למצב מת ממצב 9 (של DFSM) וכך הוא יודע שנמצאה ההתאמה הכי ארוכה.

פוקנציית First

1. S→ABCd
2. A→a1b2
3. A→a2H
4. A→ϵ
5. B→b1h
6. B→b2DH
7. B→GH
8. C→c
9. C→ϵ
10. D→d
11. G→g
12. G→ϵ
13. H→h
14. H→ϵ

<u>מוסכמות:</u>

- מחרוזות של סימני דקדוק (משתנים\טרמינלים) – α, β, γ
- משתנים (nonterminals) – B,A
- טרמינלים – a,b,c
- מחרוזות של טרמינלים – x,y,z
- המילה הריקה זו מחרוזת עם 0 סימנים, זה לא טרמינל.

1. FIRST(α) – זו קבוצה של טרמינלים\ מילה ריקה. קבוצה זו מכילה את כל הטרמינלים שהם נמצאים במקום הראשון של הצד הימני בחוקים.
   טרמינל a שייך ל – FIRST(α), אם קיימת גזירה (קיימת מחרוזת β) כך ש: $\alpha =>^* a\beta$
2. אם $\alpha =>^* \epsilon$ (אפיס α) אז ϵ שייכת ל-FIRST(α)
3. אם a טרמינל אז נגזור : FIRST(a) = {a}.
4. First של טרמינל הוא אותו הטרמינל – FIRST(a) = a

דוגמא:

FIRST(ABCd) = {a1,a2,b1}

ABCd ➔***<u>a1</u>***b2BCd
ABCd ➔***<u>a2</u>***HBCd
ABCD ➔ BCd➔***<u>b1</u>***hCd

קומפילציה

הרצת אלגוריתם לחשוב FIRST של כל משתני הדקדוק

נעבור על חוקי הגזירה ונבדוק מהם ערכי ה-FIRST של ה-nonteminals.

S	***A***	***B***	***C***	***D***	***G***	*H*
a1	a1	b1	c	d	g	h
a2	a2	b2	ϵ		ϵ	ϵ
b1	ϵ	g				
b2		h				
g		ϵ				
h						
c						
d						

פונקציית FOLLOW

FOLLOW(A) – קבוצה של טרמינלים \ $ - סוף. הוא לעולם לא כולל את ϵ, כיוון שאם היה מכיל זה אומר שכל nonterminal גוזר אפסילון.

1. טרמינל a שייך ל- FOLLOW(A) אם קיימת גזירה : $S =>^* \alpha A a \beta$, הנקודה החשובה היא ש-a מגיע ישר אחרי A
2. $ שייך ל-FOLLOW(A) אם קיימת גזירה: $S =>^* \alpha A$, כלומר אין כלום אחרי A. בנוסף $ הוא תמיד ב-FOLLOW(S) של המשתנה ההתחלתי, כיוון שאפשר לגזור ב0 צעדים מS ל-S ואז ה-$ הוא אחרי ה-S.

דוגמא:

1.S→DzDaG 2. D→ABG 3. A→Dh 4. A→a 5. B→b1h 6. B→b2

7. B→ϵ 8. D→d 9. G→g 10. G→B

FOLLOW(D) = {z,a}

FOLLOW(G) = {$,z}

S➔D<u>z</u>D<u>a</u>G➔ABG<u>z</u>DaG

אלגוריתם לחישוב FOLLOW של משתני הדקדוק

S	***A***	***B***	***D***	***G***
$	b1	b1	z	z
	b2	b2	g	a
	g	g	h	$
	z	z		h
	a	a		
	h	h		
		$		

FIRST(S) = {a,d}
FIRST(A) = {a,d}
FIRST(B) = {b1,b2,epsilon}
FIRST(D) = {a,d}
FIRST(G) = {b1,b2,gepsilon}

כדי לחשב את ה-FOLLOW, נעבוד לפי חישובי ה-FIRST של ה-nonterminals.

- *מכלל גזירה מהצורה : $A \rightarrow \alpha B \beta$, נסיק שכל הטרמינלים מ – $FIRST(\beta)$ שייכים ל- FOLLOW(B).*
- *מכלל גזירה מהצורה : $A \rightarrow \alpha B$ או $A \rightarrow \alpha_1 B \alpha_2$, כאשר α_2 אפיס, נסיק שכל איברי FOLLOW(A) שייכים ל-FOLLOW(B).*

מכלל 2, כל הטרמינלים של FIRST(B), FIRST(G) נמצאים ב-FOLLOW(A) כיוון ש-B אפיס, אז צריך להתייחס גם לטרמינלים של G.
בנוסף מכלל זה, כדי למצוא את ה- FOLLOW(A) נחפש את FIRST(B) וגם FIRST(G).

קומפילציה

Top down parsing

לאחר המנתח הלקסיקלי מגיע שלב ה-parsing, שהתוצר שלו הוא עץ גזירה לקלט נתון.

- *Statement –* משפט שמבצעים אותו, אך הוא לא מחזיר ערך. למשפט יש side effects, השמה, IF, לולאות.
- *Expression –* ביטוי שמחזיר ערך (כמו חישוב פעולות מתמטיות).
- *רקורסיה ימנית –* כאשר ה-nonterminal של הכלל נמצא בצד הימני ביותר של כלל הגזירה : $A \to \alpha A, A \to^* \alpha A$. אותו דבר גם לגבי רקורסיה שמאלית.

ה-parser יוצר טבלת LL(1) שנקראת גם predictive parsing table. הטבלה הזאת מכילה רשומות מעבר מ- nonterminals ל-terminals, ובה הוא משתמש כדי לדעת איך להגיע מ-nonterminal כלשהו בעץ גזירה לטרמינל שמופיע בקלט (מחרוזת הקלט שמטופלת בכל רגע מסומנת ע"י סמן שנקרא lookahead).

דקדוק (1)LL - הוא דקדוק עבורו אין בטבלה קונפליקטים, כלומר עבור כניסה (nonterminal) אין יותר מכלל גזירה אחד – דקדוק חד משמעי. כמו כן בדקדוק זה נדרש להסתכל רק צעד אחד קדימה במחרוזת הקלט, כלומר על התו שעליו ממוקם ה-lookahead.

לצורך בניית הטבלה נדרש לחשב את פונקציות ה-FIRST וה-FOLLOW. את ה-FOLLOW צריך לחשב בשביל האפסילון. כלומר לטבלה מכניסים את תוצאת החישוב של FOLLOW(A) אם קיים כלל A→B וגם B→epsilon.

בנית טבלה עבור predictive parsing לא רקורסיבי

קלט: דקדוק G

פלט: טבלת ניתוח תחבירי M שבה יש שורה עבור כל משתנה של G ועמודה עבור כל טרמינל של G ועבור הסימן $ המציג את סוף הקלט. **כל כניסה בטבלה יכולה להכיל** כללי גזירה (רצוי לא יותר מאחד – ראו בהמשך) או ציון של שגיאה (error).

סימון: M [A, a] היא הכניסה שמופיעה בשורה של המשתנה A ובעמודה a.

האלגוריתם:

1. עבור כל כלל גזירה (של הדקדוק G) A → α בצע את צעדים 2 ו- 3
2. עבור כל טרמינל a שנמצא ב- FIRST (α), הוסף את A → α לכניסה M [A, a]
3. אם ε נמצא ב- FIRST (α) או עבור כל טרמינל b שנמצא ב-FOLLOW (A), הוסף את A → α לכניסה M [A, b]. אם ε נמצא ב- FIRST (α) ו-$ נמצא ב- FOLLOW (A), הוסף את A → α לכניסה M [A, $].
4. כל כניסה של M שנותרה ריקה נחשבת לכניסת error.
5. אם יש כניסה אחת (או יותר) ב- M שמכילה יותר מכלל גזירה אחד אז האלגוריתם נכשל אחרת הוא מסתיים בהצלחה.

הערה: זה לא טוב כאשר כניסה בטבלה מכילה יותר מכלל גזירה אחד (זה נקרא קונפליקט) כי כאשר המנתח נזקק לכניסה זו, אין הוא יודע באיזה מהכללים הרשומים בה להשתמש.

דוגמא

הרצת האלגוריתם לבנית טבלה על הדקדוק שהובא לעיל תתן את הטבלה הבאה. המספרים בטבלה מציינים כללי גזירה. הכניסות הריקות מציינות error.

- כדי לסמן את סוף הקלט במחסנית, תמיד שמים $ לפני שדוחפים לתוכה את הקלט. כל פעם שבמחסנית מגיעים לאסימון (כלומר האסימון – טרמינל, הוא בראש המחסנית), משווים את האסימון למחרוזת/ תו הקלט שמסומן ע"י ה-lookahead.
- אם בטבלה אין גזירה למחרוזת כלשהי מכלל כלשהו, זה יתן syntax error אם הקומפיילר יתקל במקרה כזה. כלומר אם בראש המחסנית יעמוד הכלל הנ"ל והמחרוזת הנוכחית תהיה המחרוזת הנ"ל תתקבל שגיאה.

מתי נוצר קונפליקט בין כללי גזירה , $A \to^* \alpha , A \to^* \beta$

1. FIRST(α) = FIRST(β) – קיים טרמינל שגוזר מאלפא ומביטא מחרוזות המתחילות מאותו טרמינל: FIRST(β) ∩ FIRST(α).
2. המילה הריקה – אפסילון, שייכת ל - FIRST(β) ∩ FIRST(α), כלומר גם אלפא וגם ביטא אפיסות.
3. ביטא אפיסה וקיים טרמינל FOLLOW(A) ∩ FIRST(α).

לדוגמא:

S→Az

A→epsilon

A→z

דקדוק עם רקורסיה שמאלית אינו LL(1)

דקדוק כזה יוצר קונפליקט בטבלה. היות וזאת רקורסיה מיידית, ובעץ גזירה, כדי להגיע לטרמינל הרצוי, תמיד תהיה האלטרנטיבה לעבור דרך אותו ה-nonterminal שוב.

לדוגמא:

S→Az

A→Aa

A→a

קומפילציה

בניית טבלה לדקדוק LL(2)

בדקדוק LL(k) ה-parser רואה k תווים קדימה ממיקום ה-lookahead, לכן בטבלה יהיו עמודות שבהגדרתם יהיו k תווים, ובהתאם נצטרך לחשב FIRSTk וגם FOLLOWk.
בדקדוק LL(2) מסתכלים 2 תווים קדימה, לכן כל עמודה בטבלה תכיל הגדרה של 2 תווים, כלומר אם רואים את 2 התווים שבראש העמודה, באיזה כלל נשתמש לגזירה כדי להגיע למחרוזת בת 2 התווים הזאת. כמו כן בגלל זה נדרש לחשב את FIRST2 של צד ימין של חוקי הגזירה, נרצה לדעת איזה 2 תווים יהיו הראשונים בכל צד ימין של כל כלל. דקדוק LL(k+1) מכיל את דקדוק LL(k) ולכן יכול לגזור גם מחרוזות באורך עד k+1 (כמובן שאם קיימים כללי גזירה מתאימים בדקדוק). במצב של non-terminal אפיס, נצטרך לחשב את FOLLOW2.

Bottom up parsing

LR parsing

עדיף להשתמש ברקורסיה שמאלת.

- Shift: דחוף את ה-lookahead (התו הנוכחי בקלט) למחסנית והתקדם בקלט. (קרא למנתח הלקסיקלי ועדכן את ה-lookahead).
- Reduce: החלף את מה שבראש המחסנית (יכול להיות גם רצף מחרוזות שתואם את הכלל גזירה) ב-non-terminal של הכלל.

לדוגמא קיים הכלל : B →id relop num.

אז כל מחרוזת נדחפת למחסנית בתורה (פעולת shift), כשבמחסנית יהיו שלושת המחרוזות, הן תוצאנה ויכנס במקומן B (פעולת reduce). וכך בעצם נבנה הצד הימני של הכלל של S, עד שניתן לרוקן את המחסנית ולהכניס את S, מה שיציין שהקלט תקין והגענו לסופו.

פעולת ה-reduce מתבצעת לפי ה-FOLLOW של ה-non-termianl, כלומר כשה-lookahead מצא מחרוזת שהיא ב-FOLLOW של אותו ה-non-terminal, תתבצע פעולת ה-reduce לפי אורך כלל הגיזרה המתאים.

בפועל במחסנית של העץ גזירה יהיו רק המצבים של טבלת ה-SLR(1), וצמצום המחרוזות נעשה ע"י כך שבטבלה יש כמות מצבים לפי כמות המחרוזות שנקראו כביכול למחסנית, רק שבמקומם יש מספרים. כניסה ריקה בטבלה מעידה על syntax error.

בניית טבלת SLR(1)

1. מרחיבים את הדקדוק ע"י הוספת כלל גזירה S'→S (S' משתנה ההתחלתי החדש), כך שעכשיו S' יהיה השורש של עץ הגזירה של הדקדוק, אשר יסיים את סוף ה-parsing. עושים זאת כיוון שהמשתנה ההתחלתי S יכול להופיע כמה פעמים בעץ ולא ניתן להתבסס על כך שהגענו ל-S שזהו סוף הקלט.

2. בונים אוטומט פריטי LR(0). פריטים אלו הם כללי גזירה בהם יש נקודה בצד ימין של הכלל. הנקודה מציינת את התקדמות ה-parser, מה שלפני הנקודה נקרא כבר ונמצא במחסנית. אפשר ליצור קבוצות של כללים לפי מיקום הנקודה, כלומר ה-parser יעבוד במקביל על הכללי גזירה באותה הקבוצה, וזה אומר שיש כמה דרכים להמשיך מהמקום בו נמצא ה-lookahead.
האוטומט מקבל את כל המחרוזות שעשויות להיות על המחסנית במהלך הניתוח התחבירי של קלט תקין. המצב ההתחלתי של האוטומט יהיה הסגור של קבוצת הפריטים, כלומר כל כללי הגזירה של S ואם בצד הימני של כלל גזירה כלשהו יש עוד non-terminal אז גם כללי הגזירה שלו וכך הלאה.
חישוב המעברים של האוטומט מתבצע כך שמזיזים את הנקודה בעצם ימינה לאחר כל מחרוזת בצד הימני של כלל הגזירה, ובמצב הבא מחשבים את הסגור בהתאם לחוקים. והמעבר הוא בעצם אותה המחרוזת שהייתה מימין לנקודה במצב הקודם.

   כשהנקודה נמצאת בסוף המחרוזת במצב מסויים זה אומר שהגענו לסוף צד ימין של כלל כלשהו וצריך לעשות reduce.
   $A \to \alpha \diamond, A \to \diamond$ אומר שיש לעשות reduce לפי הכלל $A \to \alpha$ בכל העמודות שמתאימות לאיברי FOLLOW(A). פריט שבו יש non-terminal מימין לנקודה מתפרש בעמודות של goto בטבלה.
3. בונים את הטבלה לפי האוטומט.

קומפילציה

סגור של קבוצת פריטים

מתחילים מהכלל הראשון לאחר הוספת 'S, ומוסיפים נקודה משמאל ל-S ← $S \circ$ → 'S. לאחר מכן כותבים את כל כללי הגזירה של S ושמים את הנקודה בצד השמאלי ביותר של צד ימין של הכלל. כל non-terminal שצמוד לנקודה, צריך להוסיף את כללי הגזירה שלו לקבוצה של סגור הקבוצות, וכך הלאה.

סוגי קונפליקטים

- קונפליקט – 2 או יותר (shift / reduce) actions באותה כניסה בטבלת ה-SLR. עבור כל דקדוק קיימת טבלת SLR אחת. אם הטבלה בלי קונפליקטים, אז הדקדוק הוא SLR(1) – simple | left read input | find right most derivation | lookahead size is 1.

- ***קונפליקט מסוג shift\reduce:*** זה קורה כאשר במצב מסויים יש 2 פריטים מהצורה $A \to \alpha_1 \circ, B \to \alpha_2 \circ a\alpha_3$, ומתקיים התנאי ש-a שייך ל-FOLLOW(A). כלומר בטבלה, באותה הכניסה עבור אותו הטרמינל יש גם reduce וגם shift.
- ***קונפליקט מסוג reduce\reduce:*** זה קורה כאשר במצב מסויים יש 2 פריטים מהצורה $A \to \alpha \circ, B \to \beta \circ$ ומתקיים התנאי שקיים איבר ששייך גם ל-FOLLOW(A) וגם ל-FOLLOW(B).

דגומא לבניית טבלת SLR(1)

1. S→MG ,2. G → Gg ,3. G → ϵ ,4. M → mM ,5. M → ϵ

א. הרחבת הדקדוק – מוסיפים כלל : S → S'

ב. בניית אוטומט פריטי LR(0):

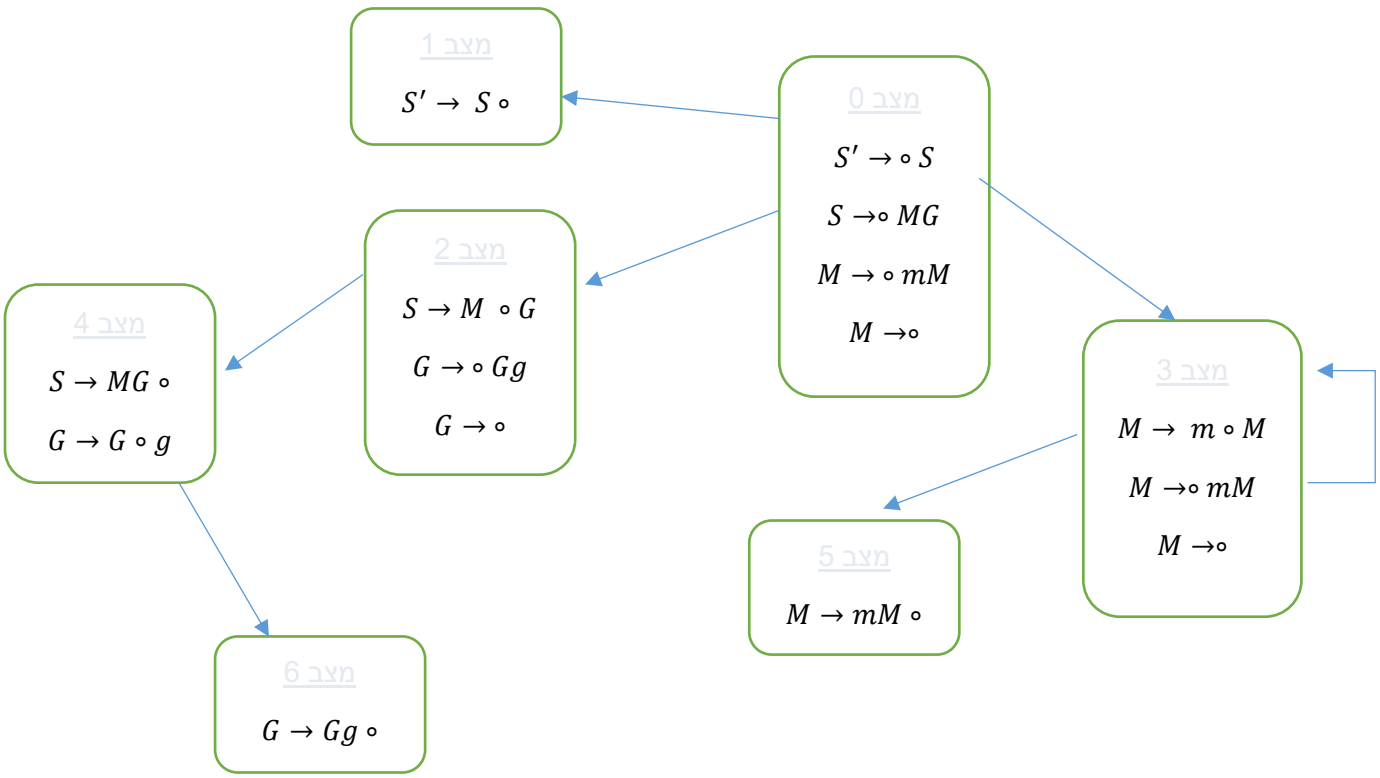

ג. בניית הטבלה:

נחשב את פונקציית FIRSTS על ה-nonTerminals:

FIRST(S) = {m,g,epsilon}

FIRST(G) = {g, epsilon}

FIRST(M) = {m ,epsilon}

נחשב את פונקציית ה-FOLLOW:

FOLLOW(S) = {$}

FOLLOW(M) = {g, $}

FOLLOW(G) = {$, g}

	action			goto		
	m	g	$	S	G	M
0	s3	r(M → ϵ)	r(M → ϵ)	1		2
1			Accept			
2		r (G → ϵ)	r(G → ϵ)		4	
3	s3	r(M → ϵ)	r(M → ϵ)			5
4		s6	r(S→MG)			
5		r(M → mM)	r(M → mM)			
6		r(G → Gg)	r(G → Gg)			

נריץ את ה-parser על הקלט mgg:

תוכן המחסנית	יתרת הקלט	action
0	mgg$	
0m3	gg$	Shift
0m3M5	gg$	Reduce by M→epsilon
0M2	gg$	Reduce by M→mM
0M2G4	gg$	Reduce by G→epsilon
0M2G4g6	g$	Shift
0M2G4	g$	Reduce by G→Gg
0M2G4g6	g$	Shift
0M2G4	$	Reduce by G→Gg
0S1	$	Reduce by S→MG
	accept	

<u>תרגיל:</u>

דקדוק לא ידוע:

קלט abcd

כמה shifts יהיו? – 4

קומפילציה

כמה פעולות reduce? – תלוי בכללי גזירה, כלומר כמה non-terminals יש בחוקי השפה, כמספר ה-nonterminals יהיה מספר reduce.

הגדרה מונחת תחביר – (SDD – sdd.doc) syntax directed definition

במקרים מסויימים נרצה לחשב ערכים בצמתים של עץ גזירה. לדוגמא בביטוי אריתמטי.

הגדרה מונחת תחביר מתארת בצורה פורמלים כיצד ניתן לחשב ערכים אלו. כלומר נוצר עץ גזירה.

יש תכונות לסימני דקדוק – attributes
<u>תכונות נבנות – synthesized</u> – צומת N בעץ הגזירה מחושבת בעזרת תכונות בילדים של N. (ואולי תכונות אחרות ב-N עצמו). אם למשתנה A יש תכונת נבנית A.s אז לכל כלל גזירה של A יש לשייך כלל סמנטי שמחשב את A.s (בעזרת תכונות של סימני דקדוק המופיעים בכלל הגזירה). תכונות של אסימונים (טרמינלים) נחשבות לתכונות נבנות.

<u>תכונות מורשות – inherited</u> – צומת N בעץ הגזירה מחושבת בעזרת תכונות באחים ובאבא של N. (ואולי תכונות אחרות ב-N עצמו). אם למשתנה A יש תכונה מורשת A.i אז לכל כלל גזירה שבו A מופיע בצד ימין. יש לשייך כלל סמנטי שמחשב את A.i (בעזרת תכונות של סימני דקדוק המופיעים בכלל הגזירה).

נשתמש בדקדוק הבא:

E→E+T

E→T

T→T*F

T→F

F→(E)

F→NUM

ניקח לדוגמא את הקלט הבא: 23 = 5*(3+4)

בדוגמא זו נעשה שימוש בתכונות נבנות.

בדוגמא שלנו התכונות הם:

- E.val – הערך של הביטוי ש-E מייצג (גוזר)
- T.val – הערך (term) של המחובר ש-T מייצג
- F.val - אותו הדבר
- NUM.lexval - הערך של האסימון

כלל גזירה	כלל סמנטי
E→E1+T	E.val = E1.val + T.val
E→T	E.val = T.val
T→T1*F	T.val = T1.val * F.val
T→F	T.val = F.val
F→(E)	F.val = E.val
F→NUM	F.val = NUM.lexval

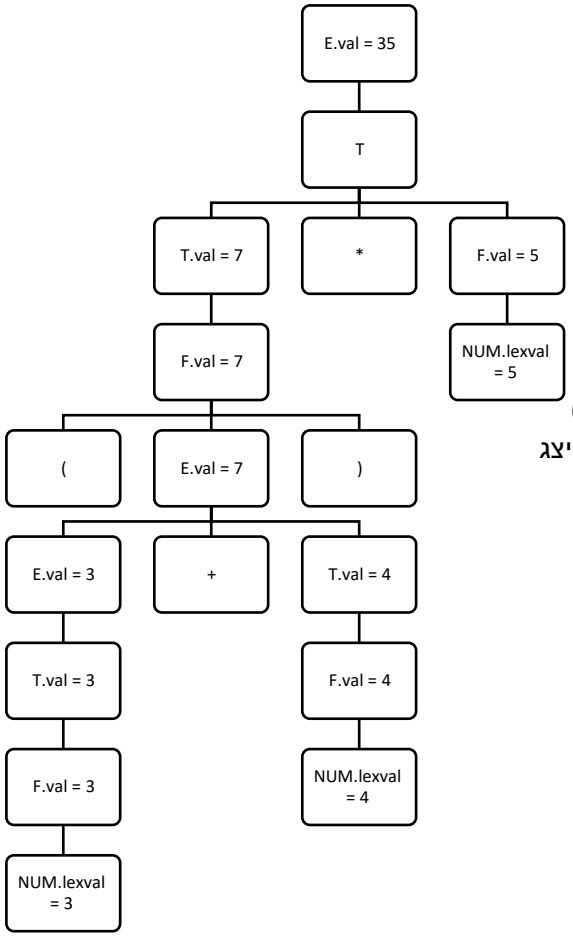

דוגמא למציאת מקסימום מבין סדרת מספרים

ניקח את סדרת המספרים הבאה: 3,1,5,4

כלל גזירה	כלל סמנטי
S→L	S.max = L.max
L→L1 ,NUM	L.max = maximum(L1.max , NUM.val)
L→NUM	L.max = NUM.val

חישוב ערך של מספר בינארי

ניקח את המחרוזת :1101 = 13

כלל גזירה	כלל סמנטי
S→L	
L→BL1	L,val = B.bit * 2^(L1.len) + L1.val L.len = 1+L1.len
L→B	L.val = B.bit L.len = 1
B→0	B.bit = 0
B→1	B.bit = 1

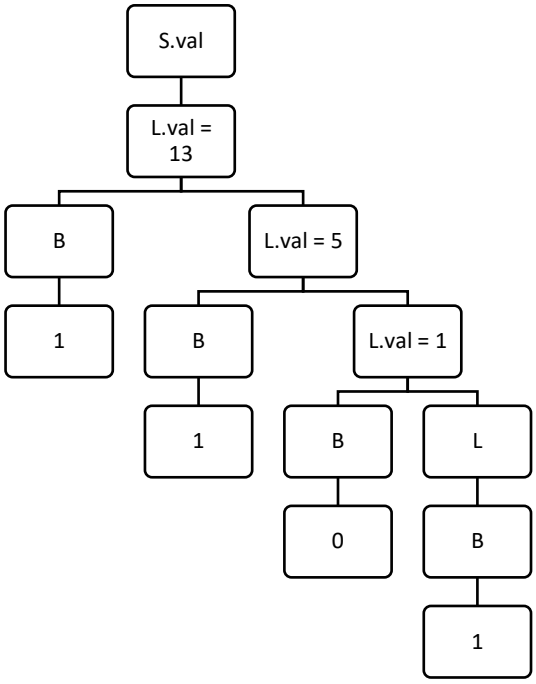

קומפילציה

Bison parse generator (גרסת קוד פתוח של yacc, של GNU)

מה עושים כדי להכין את התוכנית? (עבודה עם CMD)

1. Flex exp.lex – נוצר קובץ lex.yy.c שכולל את הפונ' yylex.
2. מריצים bison -d exp.y – נוצרים קבצים exp.tab.c ; exp.tab.h - בקובץ C נמצאת הפונקציה ()yyparse שהיא אחראית על כל העבודה.
3. מקמפלים בעזרת קומפיילר לשפת C את הקבצים שנוצרו בצעדים קודמים, למשל : gcc exp.tab.c lex.yy.c -o exp.exe
4. מריצים את התוכנית שבנינו על הקלט (למשל 3+4*5) : exp.exe mytext.txt ויודפס value is 23.

הפונקציה yylex תחזיר מס' המציין את סוג האסימון שהיא מצאה. אם לאסימון יש ערך סמנטי היא תכתוב אותו למשתנה הגלובלי yylval שהוא משתנה של bison.

בקובץ exp.y של BISON מגידירים את ה-tokens וה-type .
%token <ival> NUM אומר שהקבוע – NUM יהיה ב-ival של yylval.

%type <ival> expression term factor , מגדיר את חוקי הגזירה עבור ival , שאותם מגדירים בהמשך הקובץ. כלל הגזירה line הוא שורש העץ, אי אפשר להגיע אליו שוב במהלך הניתוח של הקלט ומשתמשים בו רק בתחילת הקלט, כמו כן אין לו ערך סמנטי (בהתאם לקלט, אפשר לחשוב על זה כשהשמה למשתנה - nonterminal) ולכן אין צורך להגדיר אותו בשורה של %type. זה גם אומר שהערך הסמנטי של כללי הגזירה האלו ($$) ישבו בשדה ival.

ככל אצבע אסימונים – טרמינלים נכתבים באותיות גדולות ומשתנים nonterminals נכתבים באותיות קטנות (אלה שמצד שמאל לכלל גזירה).

כשנעשה push למחסנית נגיד כשראינו ADDOP, אז נדחף למחסנית המשתנה yylval, שבו אגור הערך הסמנטי (+/-) של ADDOP.

בכללי גזירה ה-$$ מציין את הערך הסמנטי בעצם שמוחזר למשתנה.

בכללי גזירה כדי לעשות reduce ממשתנה למשתנה, צריך לכתוב :

Expression : term($$=$1), ואז בעצם ניתן לעבור מ-term ל-expression. וכשרוצים לעשות reduce לביטוי, צריך לבדוק את התנאים של הביטוי בכלל גזירה של במשתנה. כל זה לפי מצב המחסנית.

לדוגמא:

עבור הקלט 3+4*5. 3 נכנס בהתחלה למחסנית, זהו אסימון NUM לפי ה-flex, לכן הוא יכנס תחילה ל-factor (זהו הערך הסמנטי שלו), ו-$$=3. לאחר מכן יש במחסנית factor($$=$1) כי יש רק ביטוי אחד, ומזה ניתן לעשות צמצום ל-term וכך הלאה. כשמגיעים למצב שיש ביטוי במחסנית כמו term = 4, MULOP = * , factor = 5, אפשר לצמצם את זה ע"י termMULOP factor כשנעשים הבדיקות הנדרשות וזה יצומצם ל-expression.

הפעולות של 3+4*5: רואים את 4 במחסנית, מחליפים אותו ב-NUM ועושים reduce ל-factor לפי הכלל גזירה שלו, ומצמום נוסף ל-term לאחר מכן רואים '*' ומחליפים אותו ב-MULOP , לאחר מכן רואים 5, מחליפים אותו ב-NUM ואז ל-FACTOR, ואז מתקבל במחסנית הביטוי term MULOP factor. לפי החוקי גזירה ובניית האוטומט הוא יודע לא לצמצם את ה-term ל-expression.

המשתנה yyvsp מייצג את המחסנית, שנשמרת במערך. yyvsp[-1] = Yyvsp[(2)-(3)] כלומר ניגש לראש המחסנית. האינדקסים עובדים הפוך – בסדר שלילי. 2- זה האיבר מתחת לראש המחסנית וכו'.

קומפילציה

דוגמא ל-struct:

נגדיר את ה-struct:

```
%code requires {
        Struct mydate {
                Int day, month, year;
                }
        %union {
                Struct mydate d;
                Int ival;
                }
        %token <ival> NUM
        %type <d> date
                }
date: NUM '/' NUM '/' NUM
        $1  $2   $3    $4   $5
        { $$.day = $1;
         $$.month = $3;
         $$.year = $5; }
Line : date { printf("day = %d, month = %d, year = %d", $1.day, $1.month, $1.year)}
```

$1 מייצג את ה-date בכלל גזירה של line, אשר הוא שמור ב-d שהוא מטיפוס mydate ולא יש את השדות day,month,year.

קומפילציה

דוגמא להגדרה מונת תחביר של סדרת פיבונא'צי: 011235

תכונות :

- NUM.val – המספר
- S.fib – האם זו סדרת פיבונאצ'י (בעל ערך true/false).
- L.fib – האם סדרת המספרים ש-L מייצג היא סדרת פיבונאצ'י (בעל ערך true/false).
- L.sum2 – סכום 2 המספרים האחרונים בסדרה L

S→L	S.fib = L.fib
L → L NUM	L.fib = L1.fib && L1.sum2 == NUM.val L.sum2 = L1.last + NUM.val L.lsat = NUM.val

L → NUM1 NUM2	If (NUM1.val == 0 && NUM2.val ==1)
	L.fib = true;
	else L.fib = false;
	L.sum2 = NUM1.val + NUM2.val
	L.last = NUM2.val

SDD המתאר בניית AST (abstract syntax tree) עבור ביטויים אריתמטיים

המטרה כאן היא לבנות syntax tree של ביטוי אריתמטי ולא לחשב אותו. כלומר נרצה לקבל את עץ שמכיל ערכים סמנטים לפי כללי הגזירה. (עץ שהקומפיילר יכול לבנות לעצמו):

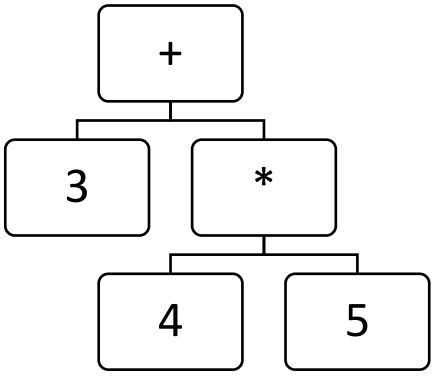

כל עלה בעץ הזה הוא מספר (למרות שיכול להיות גם משתנה, אבל לא מטפלים בזה כרגע). מטרת הקומפיילר לבניית העץ הזה הוא לבדוק תקינות סינטקס של ביטויים אריתמטיים. דוגמא לבניית העץ:

P1 = mkleaf(3);
p2 = mkleaf(4);
p3 = mkleaf(5);
p4 = mknode(*,p2,p3);
p5 = mknode(+,p1,p4);

P הוא פויינטר לצומת בעץ (כולל עלים).

כלל גזירה	כלל סמנטי
E→E1+T	E.tree = mknode(+,E1.tree,T.tree)
E→T	E.tree = T.tree
T→T1*F	T.tree = mknode(*,T1.tree,F.tree)
T→F	T.tree = F.tree
F→(E)	F.tree = E.tree
F→NUM	F.tree = mkleaf(NUM.val)

<u>תכונות:</u>

- NUM.val – המספר בביטוי האריתמטי
- E.tree – syntax tree עבור הביטוי E
- T.tree
- F.tree

דוגמא פשוטה לשימוש בתכונה מורשת

נרצה לחשב את התכונה המורשת C.pos (המיקום של C – תו, בקלט).

L.len – אורך המחרוזת ש-L מייצג.

כלל גזירה	כלל סמנטי
S→L	
L→L'C	C.pos = L'.len L.len = L'.len + 1
L→C	C.pos = 0 L.len = 1
C→a	
C→b	

דוגמא נוספת

חישוב ערך של מספר בינארי : 1101 = 13

B.w – המשקל של הסיבית, תכונה מורשת. מכיוון שמשתמשים ב"אח" של B כדי לחשב אותה (L.len)

B.bit – תכונה נבנית, ערך הסיבית.

ניתן לקשט את העץ, כלומר לחשב את ערכי התכונות בכל הצמתים של עץ הגזירה, בסדר הבא:

- נחשב את B.bit בכל הצמתים המסומנים ב-B.
- נחשב את L.len בכל הצמתים המסומנים ב-L. (מלמטה למעלה).
- נחשב את B.w בכל הצמתים המסומנים ב-B. (הסדר לא חשוב).
- נחשב את L.val בכל הצמתים המסומנים ב-L.
- נחשב את S.val.

הערה: ההגדרה אינה מסוג L.

כלל גזירה	כלל סמנטי
S→L	S.val = L.val
L→BL1	B.w = 2^(L1.len) L.len = L1.len + 1 l.val = L1.val + B.bit*B.w
L→B	B.w = 1 L.len = 1 L.val = B.bit
B→1	B.bit = 1
B→0	B.bit = 0

אלגוריתם למציאת סדר חישוב תכונות בצמתים של עץ גזירה

הבעיה היא כשיש תכונות מורשות (כי בתכונות נבנות זה מלמטה למעלה תמיד), כיוון שאפשר לחשב חלק מהתכונות ללא כל סדר, ואילו תכונות אחרות תלויות בתכונות מסויימות ולהן נדרש סדר חישוב. ניתן להסתכל על סדר חישוב התכונות כעל מטלות בעלות סדר היררכי. לכן ניתן לעשות עליהן *מיון טופולוגי*.

בונים גרף תלויות שבו כל צומת מייצג "מטלה" – חישוב תכונה מסויימת בצומת מסויים בעץ הגזירה. בגרף תהיה קשה מ"מטלה" X ל"מטלה" Y אם צריך לבצע את X לפני Y. ועל גרף זה עושים מיון טופולוגי.

קומפילציה

דוגמא נוספת

L.val – סכום התרומות של הסיביות שמרכיבות את L לתוצאה הסופית.
L.in – כמה סיביות יש מימין לL. (תכונה מורשת – כיוון שמשתמשים בתכונה של האבא).
B.bit
B.w – המשקל של B (תכונה מורשת).

כלל גזירה	כלל סמנטי
S→L	L.in = 0
L→ L1B	B.w = 2^L.in L1.in = L.in +1 L.val = L1.val + B.bit*B.w
L→B	B.w = 2^L.in L.val = B.bit * B.w
B→1	B.bit = 1
B→0	B.bit = 0

L – attributed definition

הגדרה מונחית תחביר היא L-attributed אם כל החישובים של התכונות המורשות תלויות רק בתכונות של האבא ובתכונות של האחים השמאליים. כיוון שחישוב ערכי התכונות בעץ גזירה בהגדרה מסוג L מתבצע ברקורסיה משמאל לימין בעץ, וכל לכל צומת קיימות התכונות רק של האבא ושל האחים השמאליים. בעצם מתבצע DFS משמאל לימין. התהליך הוא לרדת לעלה השמאלי ביותר, לחשב את התכונות שלו, לעבור לאח הימני שלו ולחשב את התכונות שלו. בדרך לעלה השמאלי מחשבים את התכונות המורשות של כל צומת (בעצם של כל אבא עד לעלה). אחרי שמחשבים את כל הילדים של התת עץ השמאלי הקטן ביותר (כלומר את הילדים שלו) עולים חזרה לאבא (כמו שיטת post-order), ומחשבים את התכונות הנבנות של האבא.

קוד ביניים – intermediate code

Source program → [frontend, lexer, parser semantical analyzer]תלוי שפת תכנות → קוד ביניים → [backend,מחולל קוד מטרה]
→target code (assembly …) → assembler → machine code

למה צריך קוד ביניים

- מודלריות – חלוקה ל- frontend ו- backend . זה מאפשר להחליף שפת תכנות ולהשפיע רק על ה-frontend או לחליפין להחליף מעבד ולהשפיע רק על ה-backend.
- כדי שנוכל להפעיל אלגוריתמים לאופטימיזציה שאינה תלויה במעבד ספציפי.
- קל יותר לייצר קוד מטרה מקוד ביניים מאשר משפת המקור – source language.

בקוד ביניים המטרה היא לפשט את הקוד כמה שניתן, לכן מתשמשים רק באופרטור יחיד (בנוסף להשמה) כמו: a = b+c, a = b, if a>0 goto

דוגמא:

תכונות : כל התכונות במקרה הזה הן נבנות

- ID.name – שם האסימון (הייצוג שלו בתור מחרוזת).
- Stmt.code – התרגום של המשפט לקוד ביניים.
- Exp.code – התרגום של הביטוי לקוד ביניים. הקוד מחשב את הביטוי וכותב את התוצאה למשתנה exp.result.

כלל גזירה	כלל סמנטי
Stmt → ID = exp;	Stmt.code = exp.code || gen(ID.name '=' exp.result)
Exp → exp1 + exp2	Exp.result = newtemp(); Exp.code = exp1.code || exp2.code || gen(exp.result '=' exp1.reuslt '+' exp2.result)
Exp → exp1 * exp2	Exp.result = newtemp(); Exp.code = exp1.code || exp2.code || gen(exp.result '=' exp1.reuslt '*' exp2.result)
Exp → (exp1)	Exp.code = exp1.code Exp.result = exp1.result
Exp → ID	Exp.code = "" Exp.result = ID.name

נשתמש בקלט : a = (b+c)*(d+f)

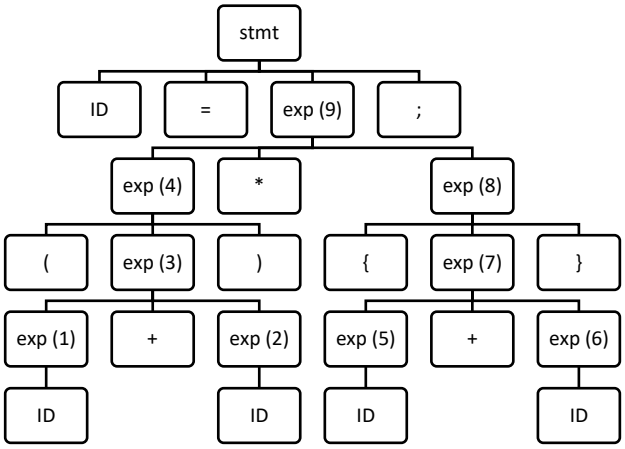

קוד ביניים:

T1 = b+c
t2 = d+f
t3 = t1*t2
a = t3

כדי לייצר את המשתנים הזמניים t1,t2,t3 נשתמש בפונקציה newtemp –.

דוגמת הרצה:

Exp1.code = "", exp1.result = ID.name = b

Exp2.code = "", exp2.result = ID.name = c

Exp3.result = newtemp() → t1, exp3.code = ""||""||t1 = b+c

Exp4.result = exp3.result = t1, exp4.code = t1=b+c

Exp5.code = "", exp5.result = ID.name = d

Exp6.code = "", exp6.result = ID.name = f

Exp7.result = newtemp() → t2, exp7.code = ""||""||t2 = d+f

Exp8.result = exp7.result = t2, exp8.code = t2= d+f

Exp9.result = newtemp() → t3, exp9.code = t3 = (b+c)*(d+f)

קומפילציה

קוד ביניים עבור משפטי while

נראה כיצד נראה תרגום של משפטים while לקוד ביניים. לצורך כך נשתמש בהגדרה מונחת תחביר.

While(y<3)
a = (b+c) * (d + f)

- Boolexp.code – התרגום של המשפט לקוד ביניים.
- Boolexp.
- Newlabel() – פונ' שיוצרת תווית חדשה, L1,L2

L2 : if false y<3 goto L1
t1 = b+c
t2 = d+f
t3 = t1*t2
a = t3
goto L2
L1 :

כלל גזירה	כלל סמנטי
Stmt → ID = exp;	Stmt.code = exp.code || gen(ID.name '=' exp.result)
Exp → exp1 + exp2	Exp.result = newtemp(); Exp.code = exp1.code || exp2.code || gen(exp.result '=' exp1.reuslt '+' exp2.result)
Exp → exp1 * exp2	Exp.result = newtemp(); Exp.code = exp1.code || exp2.code || gen(exp.result '=' exp1.reuslt '*' exp2.result)
Exp → (exp1)	Exp.code = exp1.code Exp.result = exp1.result
Exp → ID	Exp.code = "" Exp.result = ID.name
Boolexp → ID RELOP NUM	Boolexp.label = newlabel() – *(creates L1 label, in an attribute of boolexp, it's needed in more places)* Boolexp.code = gen("if False" ID.name RELOP.op NUM.val "goto" boolexp.label)
Stmt → WHILE(boolexp) stmt1	Startlabel = newlabel() – *(create L2 label, assign it to a local variable)* Stmt.code = gen(startlabel":")||boolexp.code||stmt1.code||gen("goto" starlabel)||gen(boolexp.label":")

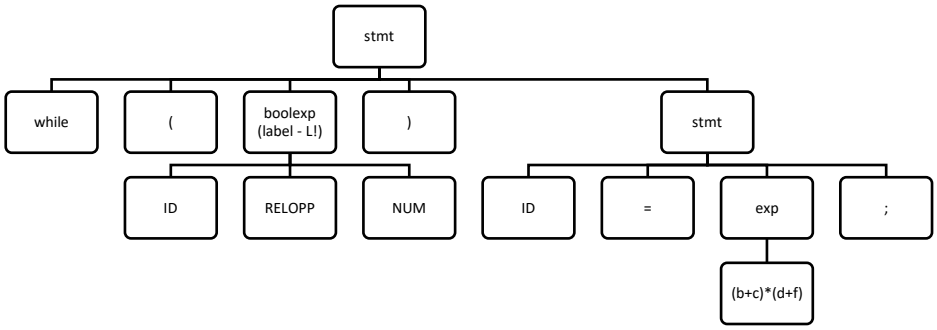

עץ הגזירה של הדוגמא הזו (חלקי, החלק החסר נמצא בדוגמא הקודמת של exp).

לרוב ניצור if False בלולאת while , כיוון ש-while זאת לא פקודה בקוד ביניים, לעומת זאת if זאת פקודה קיימת בקוד ביניים.

קוד ביניים עבור משפטי if

```
If(y<3)
a = (b+c)*(d+f);
else
a = h+g
```

```
If False y<3 goto L1
t1 = b+c
t2 = d+f
t3 = t1*t2
a = t3
goto L2
L1: t4 = h+g
a = t4
L2:
```

טבלת כללי גזירה חלקית (הדברים החסרים בטבלאות הקודמות).

כלל גזירה	כלל סמנטי
Boolexp → ID RELOP NUM	Boolexp.label = newlabel() – יוצר תווית 'אל1' Boolexp.code = gen("if False" ID.name RELOP.op NUM.val "goto" boolexp.label)
Stmt → IF(boolexp) stmt1 ELSE stmt2	Exit_label = newlabel() – *(creates L2 label, exit_label is a local variable)* Stmt.code = boolexp.code||stmt1.code||gen("goto" exit_label) ||gen(boolexp.label":")||stmt2.code||gen(exit_label":")

תרגיל 2:

-אופציה א' - ניתן לייצר קוד ביניים במהלך ה-parsing

-אופציה ב' - ה-parser מייצר AST (abstract syntax tree), עושים מעבר על העץ ומייצרים קוד ביניים.

דוגמא ל- AST עבור הקוד:

while(7+foo <= 13)

a = b(c+d)*

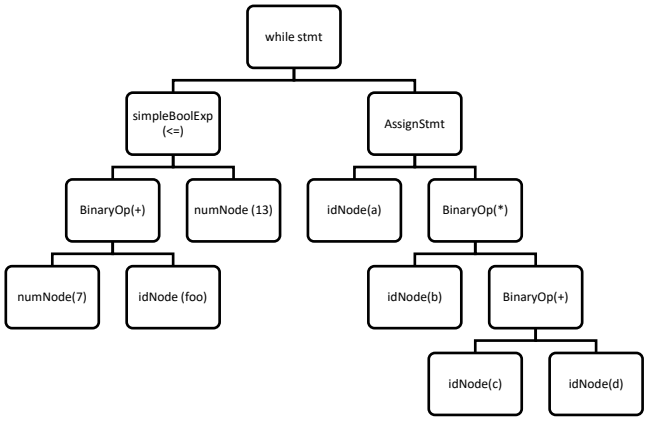

משתנה FALL_THROUGH- אומר שאם התנאי הוא אמת, אז תמשיך לגוף הביטוי, אם שקר תעבור לתווית אחרת.
ב-bison יש סימון נוסף - @ שהוא מסמן location של האסימון בקלט. Ylex כותבת את המיקום של האסימון לתוך המשתנה הגלובלי - yylloc – lexical location . Bison מנהל אוטומטית גם את מיקום המשתנים – נונטרמינלים.

היררכיה של המחלקות של ה-AST

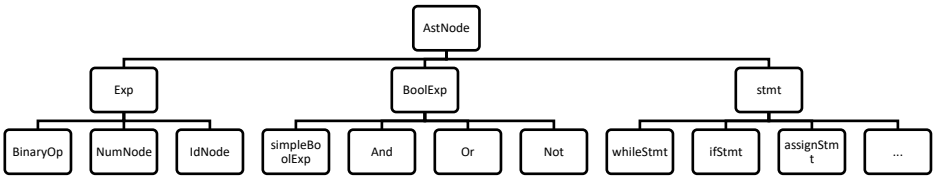

דוגמא לייצור קוד ביניים במהלך ה-parsing עם bison

כלל גזירה	ייצור קוד ביניים (קוד שנכתב בתוך ה-scope של כלל הגזירה)
Stmt → ID = exp;	Emit ($1 '=' $3) - $3 has the t3 var, which representing the result
Exp → exp1 + exp2	$$ = newtemp() – will create the temp vars t1 and t2 emit ($$ '=' $1 '*' $3) – write the medCode to the file
Exp → exp1 * exp2	$$ = newtemp() – will create the temp var t3 emit ($$ '=' $1 '*' $3)
Exp → (exp1)	$$ = $2
Exp → ID	$$ = $1

קוד ביניים מייצג רק שינויים
בערכים של המשתנים, כלומר בפעולה שבה אין שינוי בערך המשתנה אין צורך לקוד ביניים. כמו בכלל גזירה: exp→(exp1)

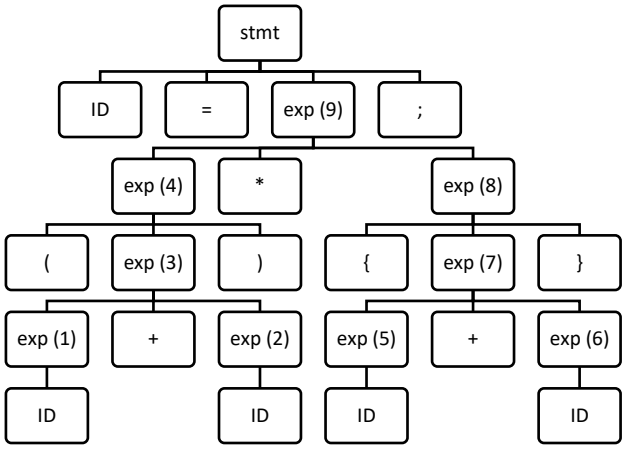

ערך סמנטי עבור כל צומת – exp יהיה אותו המשתנה שיחזיק
את תוצאת החישוב של אותו הצומת .
לדוגמא: עבור הקלט ;a = (b+c)*(d+f)
והקוד הביניים:

T1 = b+c
t2 = d+f
t3 = t1*t2
a = t3

הצומת של exp(9) יחזיק את המשתנה t3, כיוון שכרגע אין
מספרים לכל המשתנים, וכמו כן התוצאה יכולה להשתנות בכל
קלט או בריצה בלולאה (אנחנו בונים קוד ביניים כללי עבור כל קלט אפשרי תקין)

דוגמא ללולאת while:

עבור הקלט :
while(y<3)
a = (b+c)*(d+f)

כלל גזירה	קוד ביניים
Boolexp → ID RELOP NUM	$$ = newLabel() emit("if False" $1 $2 $3 "goto" $$)
Stmt → WHILE(boolexp) stmt1	After the WHILE we want to create ne label for the medCode So we can write: {$$ = newlabel() emit($$":")} – in this case bison will create a var for the rule (the $$ is for the rule and not representing the semantic value of the 'stmt') Or we can place another rule as 'beginLoop' (bison will do it in the background for the previous case). beginLoop: $empty { $$ = newLabel() emit($$":") } The type for the midRuleAction $$ will be defined as: $<--->$, in the diamond braced will be the type of the var from the union When the parser will work on the last stmt it will create the medCode for the while scope, and in the end we need to add the "goto" : {emit "goto" $2) – the $2 is the new label in the beginLoop Emit($4":") - $4 is the label in the boolexp

Backpatching

בקוד ביניים, כשנרצה לעבור בעזרת goto לפקודה אחרת, במקום תווית כמו שראינו עד עכשיו, "נקפוץ" למספר כלשהו, אשר מייצג את מיקום הפקודה (בשורות).

לדוגמא:

While(y<3)
a = (b+c)*(d+f)

כשניצור את הקוד ביניים, אנחנו לא נדע מה יהיה אורך הגוף של הלולאה ולכן נשלים את ה-goto הראשון רק אחרי שנסיים להפוך את גוף הלולאה לקוד ביניים.

100 : if false y<3 goto ***__106***
101:t1 = b+c
102:t2 = d+f
103:t3 = t1*t2
104:a = t3
105:goto 100

Emit – מוסיפה פקודה בקוד ביניים למערך של פקודות לכניסה הפנוייה הבאה עם אינקס next_instr, ומקדמת את next_instr. זהו משתנה גלובלי בתוך הפקודה emit.
בדוגמא הנ"ל נכתוב backpatch(100,106), פקודה שאומרת מאיזו שורה לקפוץ לאיזו שורה. Backpatch זאת פקודה שאנחנו צריכים לכתוב, וכל מה שהיא עושה זה אומרת לbison, לך לשורה 100 (במקרה שלנו) ותכתוב שם ב-goto את 106.

כלל הגזירה עבור הדוגמא:

```
Boolexp: ID RELOP NUM
{
        $$ = next_instr
        emit("if False" $1 $2 $3 "goto _ "); }
```

אנחנו נרצה לחזור לפקודה הזו ולהגדיר את ה-next_instr ולכן נתייחס אליו כערך הסמנטי של boolexp.

```
Stmt: WHILE '(' boolexp ')'
        stmt
        { emit("goto"$3)
          backpatch($3, next_instr); }
```

$3 זה הערך הסמנטי של boolexp בכלל הזה, ואנחנו רוצים לכתוב בסוף גוף ה-while את פקודת הקפיצה, goto 100,
ו$3 = (boolexp)next_instr = 100. כמו כן נרצה להשלים את ה-goto הראשון (106) ולכן נעדכן עם פקודת backpatch את הערך הסמנטי של boolexp לשורה הנוכחית.

דוגמא עבור if

```
If(y<3)
a = (b+c)*(d+f);
else
a = h+g
```

100:If False y<3 goto **106**
101: t1 = b+c
102: t2 = d+f
103: t3 = t1*t2
104: a = t3
105: goto **108**
106: L1: t4 = h+g
107: a = t4
108:….

```
Boolexp: ID RELOP NUM
{
        $$ = next_instr
        emit("if False" $1 $2 $3 "goto _ "); }

Stmt: IF '(' boolexp ')'
          stmt
          ELSE
        { $$ = next_instr;
          emit( "goto" __ ); }
          stmt
          { backpatch ($3, $7+1)
            backpatch($7, next_instr); }
```

Another way to remember the instruction line:
Else marker { emit ("goto" __); }
…
marker : /* empty*/ { $$ = next_instr ;}

קומפילציה

איך זה עובד?

כשמריצים קוד, יש מחסנית קריאות שבה נשמרים פעולות וקריאות לפונקציות. עבור קריאות לפונקנציות, במחסנית הקריאות יש מחסנית פריימים נוספת ששומרת את סדר הקריאות של הפונקציות (מתוך פונקציות), כיוון שצריכים סדר LIFO ביציאה מהפונקציות.

Access link(static link)- מצביע לרשומת הפעלה של הפונקציה שמקיפה את הפונקציה הנוכחית. יש שפות שמאפשרות כתיבה של פונקציה בתוך פונקציה (כמו פייתון). **לפני הריצה**, במצב סטטי, ניתן לראות את היררכיית הקריאות של הפונקציות המקוננות, לפי הקריאות באותן הפונקציות. לכן כשרוצים לקרוא לפונקציה מקיפה מהפונקציה המקוננת הנוכחית, צריכים את ה-access link וכך ניתן לגשת גם לפרמטרים של הפונקציה המקיפה. ה-ARP של ה-access link תמיד מצביע על תחילת הפונק' העוטפת הקודמת ברמת הקינון וכדי לגשת למשתנה בפונקציה העוטפת נגיע ל-ARP של הפונק' העוטפת, ונוסיף לכתובת הזו את ה-offset של המשתנה (ה- offset בהנחה שהוא ידוע). לכן אם נרצה לעבור מרמת קינות 3 לרמת קינון 0, נצרטך לגשת 3 פעמים ל-ARP , כל פעם של פונק' ברמה אחת מעלה, כלומר נעבור לARP של רמה 2, ואז ל-ARP של רמה 1 ולבסוף ל-ARP של רמה 0.

Dynamic link- מציע לרשומת ההפעלה של הפונקציה שקראה לפונקציה הנוכחית (לא פונקציות מקוננות). אם לדוגמא פונקציה פנימית, נקרא לה r2, קוראת לפונקציה שעוטפת אותה, נקרא לה p1, החיבור הזה הוא dynamic link.

אם פונ' r2 נמצאת ברמת קינון 3, והיא צריכה להגיע למשתנה שנמצא בפונקציה העוטפת הראשונה, ברמה 0, הקומפיילר יודע איפה הוא נמצא כרגע והוא יודע באיזו רמת קינון נמצא המשתנה, אז בזכות ה-access link הוא יחסיר את רמת הקינון הרצויה (0) מרמת הקינון הנוכחית (3) וככה הוא ידע כמה מצביעים הוא יצטרך לחזור.

איך מוקם access link בזמן קריאה לפונקציה

הפונ' הקוראת אחראית להקמת ה-access link.

מקרה א':

פונ' f' קוראת ל-g (יתכן ש-g,f זאת אותה הפונקציה)., בתיהן באותה רמת קינון. בגלל ששתיהן באותה רמת קינון, יש להן את אותו ה-access link, לכן ה-ARP של g יהיה זהה ל-ARP של f. F תעתיק את ה-access link של עצמה לרשומות של g.

מקרה ב':

F קוראת ל-g.

$n_g = n_f + 1$, (n זאת רמת הקינון, n_g רמת הקינון של פונקציה g). כלומר רמת הקינון של g שווה לרמת הקינון של f+1. לכן בהכרח g מקוננת ישירות בתוך f, ולכן ה-access link של g יהיה זהה ל-ARP של f.

מקרה ג':

F קוראת ל-G.

$n_g < n_f$, כלומר רמת הקינון של g קטנה מזו של f. עוקבים אחרי $n_f - n_g$ מצביעים ברשימת ה-access link המתחילה ב- access link של f ושם מוצאת אץ ה-access link של g. זה אומר בהכרח ששני הפונקציות מקוננות תחת אותה פונ' עוטפת כלשהי.

קומפילציה

Linker

Source conde → compiler → assembly code → assembler → relocatable object code →linker

Assembler מייצר קובץ הכולל: data segment, code segment, symbol table for external symbols, relocation info

External symbols הם אותם הסמלים (משתנים גלובליים ופונקציות) אשר עושים בהם שימוש בקובץ אחד וההגדרה שלהם נמצאת בקובץ אחר. הצורך ב-symbol table נובע מכך שכשהקוד עובר קומפילציה, הקומפיילר לא יודע איפה ההגדרה (מימוש) של אותה הפונקציה, כמו כן גם האסמבלר לא יודע איפה הפונ' ממומשת, כיוון שהקומפיילרים עובדים קובץ קובץ ולא מקשרים בין קבצים.
האסמבל מייצר קוד בשפת מכונה, והלינקר כבר אחראי על הקישור בין הקבצים וככה גם בין קריאת הפונ' לבין ההגדרה שלה. האמסבל מייצר את ה-symbol table שנמצא ב-object file והלינקר משתמש בו.

- כשכותבים בקוד C : #include <stdio.h>, הקומפיילר יחליף את השורה הזו בקוד, בתוכן של כל הקובץ. לרוב אין שם את המימוש של הפונקציות אלא רק את החתימות, המימוש של הקוד נמצא בקבצים מקומפלים בספריות. הלינקר ישתיל בתוך הקוד שלנו בסוף את הפונקציות שהשתמשנו בהם בקוד, ולא את כל המימושים של כל הפונקציות.

עבור כל קובץ, האסמבל יוצר code segments, ככה שכל אחד מהם שמור במקום אחר בזכרון. הלינקר לוקח את אותם הסגמנטים ויוצר בינהם הקשר, ככה שכל הכתובות שהיו בכל סגמנט (שהיו יחסיות לאותו הסגמנט) יהיו עכשיו כתובות שהלינקר מכיר וידע לגשת אליהם, כשהוא מקבץ את הסגמנטים לבלוק אחד גדול (לאו דווקא שמור ברצף בזכרון), אבל הכתובות היחסיות בכל סגמנט הופכות להיות כתובות מקושרות בין כל הסגמנטים ויחסיות עכשיו לכל הסגמנטים.

אלגוריתם תכנות דינאמי לייצור קוד אופטימלי (בשפת אסמבלי) עבור ביטויים אריתמטיים

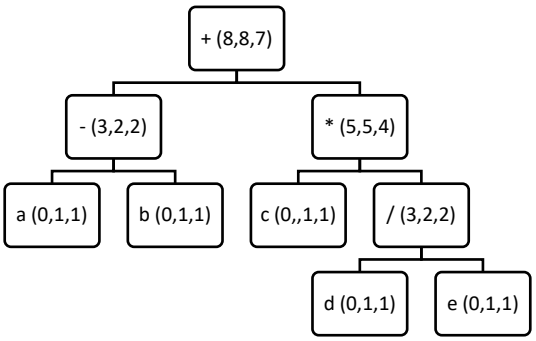

ה-syntax tree מייצג את הביטוי הבא: (a-b) + (c*(d/e))

כדי להקל על החישובים, נניח כי למעבד יש רק 2 רגיסטרים – r0,r1, ועלויות של כל הפקודות זהות (נגיד 1).

1. מחשבים וקטורי מחירים בכל הצמתים. לכל פעולה, הקומפיילר מחזיק "מחיר" עבור אותה הפעולה, כדי שיוכל לתעדף פעולות זולות יותר.
המחירים בעץ ליד האופרטורים מייצגים:
   a. הערך הימני בוקטור המחירים מייצג את מחיר חישוב הביטוי (לתוך הרגיסטר) כאשר לרשותינו עומדים 2 רגיסטרים.
   b. הערך האמצעי בוקטור מייצג את המחיר כמו הימני אם לרשותינו עומד רק רגיסטר אחד.
   c. הערך השמאלי מייצג את מחיר החישוב של הביטוי כאשר התוצאה נשמרת בזכרון.
2. מייצרים את הקוד.

הסבר על עלה a: לחשב את a זה אומר שצריך לטעון הערך שלו מהזכרון לרגיסטר: load ro a (טעינה של הערך של a מהזכרון לרגיסטר r0) ולכן העלות של פעולה זו 1 (גם כשיש לרשותינו 2 רגיסטרים וגם כשיש אחד, כי צריך רק רגיסטר אחד), והעלות לשמור את הערך הזה בזכרון היא 0 כי הוא כבר בזכרון, ולכן וקטור המחירים שלו הוא (0,1,1).

<u>חישוב וקטור המחירים בצומת עם המינוס:</u>

א. לרשותינו רגיסטר בודד – חייבים להתשמש בפקודה מהסוג : sub r r m
חישוב אופרנד ימני לתוך הזכרון – 0 (המשתנה m)
חישוב אופרנד שמאלי לתוך הרגיסטר – 1 (המשתנה r האמצעי) – כאשר לרשותינו רגיסטר 1 (רואים ב-a שהעלות היא 1)
מחיר ה-sub- חישוב של החיסור בין r-m כלומר a-b, המחיר הוא 1.
עכשיו נצטרך לסכום: 2 = 1+1+0 ולכן בצומת של המינוס בעץ, בוקטור הערך האמצעי הוא 2 (הערך עבור רגיסטר אחד).

ב. לרשותינו 2 רגיסטרים –

a. אופציה ראשונה היא לפתור את החיסור כמו ב-א' ואז התוצאה תצא גם 2.

b. אופציה שנייה להשתמש בפקודה : sub r r r, כלומר ערכי 2 האופרדנים נמצאים ברגיסטר. במצב כזה אנחנו יכולים לחשב בסדר שונה כל אופרנד (כלומר אם לכל אופרנד היה עוד תת עץ שנדרש היה לחשב את הערך שלו). אם נחשב קודם את האופרנד הימני (הערך שלו כבר יהיה שמור באחד הרגיסטרים, והיות ויש לנו רק 2 רגיסטרים, אז ישאר רק רגיסטר אחד לחישוב האופרנד השמאלי. לכן נבחן את העלויות של כל אופרנד ביחס לכמה רגיסטרים יש לו, בעץ שלנו רואים שהערכים זהים עבור 2 האופרנדים בשני המצבים של הרגיסטרים, ולכן זה לא משנה איזה אופרנד נחשב קודם). נגיד ונחשב את האופרנד השמאלי קודם, הערך שלו ישמר ב-r האמצעי (רגיסטר r0 או r1) בפקודת ה-sub, והעלות של החישוב הזה הוא 1 – לפי הוקטור מחירים של a עם 2 רגיסטרים. לאחר מכן נשאר לנו רגיסטר אחד פנוי לחישוב האופרנד הימני, העלות של פעולה זו היא 1 – לפי וקטור המחירים של b עם רגיסטר בודד, והערך של חישוב זה יכנס לרגיסטר r הימני בפקודת sub. וכעת נותר לנו לחשב את הפקודה עצמה שהעלות של חישוב זה היא 1. ולכן אם נסכום את העלויות, התוצאה היא 3 והיא גבוהה יותר מאופציה א'. ולכן נעדיף להשתמש באופציה א'.

ג. רוצים לאסחן את התוצאה בזכרון – אין פקודה שמחשבת חיסור וגם שומרת לזכרון, לכן בשלב הראשון יש לנו 2 רגיסטרים וכבר ראינו שחישוב פעולת החיסור האופטימלי עולה 2, ועכשיו נרצה לאחסן את התוצאה לזכרון, פקודת store תעלה עוד 1 ולכן סה"כ יצא שהעלות של חישוב החיסור ואחסון התוצאה בזכרון היא 3. (ככלל אצבע, נתבונן על העלות עם 2 רגיסטרים ונסיף לו 1 עבור פקודת store).

<u>חישוב וקטור המחירים בשורש</u>

א. לרשותינו רגיסטר בודד – חייבים להשתמש בפקודה add r r m. לפי הצומת של הכפל רואים שכדי לחשב את כל תת העץ הימני ולאסחן אותו בזכרון יעלה 5. לכן חישוב האופרנד הימני לזכרון בפקודת add יעלה 5. העלות של הכנסת האופרנד השמאלי לרגיסטר בודד (לפי תת העץ השמאלי) יעלה 2 ולבסוף פקודת add עולה 1. אם נסכום העלות הכוללת תהיה 8 = 1+2+5.

ב. לרשותינו 2 רגיסטרים –

a. אופציה א', שימוש בפקודה add r r m. אז התוצאה תצאה כמו ב-א'. (כיוון שגם פה שומרים את האופרנד בימני לזכרון)

b. אופציה ב', שימוש בפקודה add r r r. במצב שבו נרצה לחשב קודם את האופרנד השמאלי שיעלה 2 (מהצומת של המינוס) ולאחר מכן ישאר לנו רגיסטר בודד עבור האופרנד הימני והעלות של החישוב הזה היא 5 ועוד העלות של add, לכן סה"כ יצא 8.

c. אופציה ג', שימוש בפקודה add r r r כאשר נחשב קודם את האופרנד הימני, לפי התת עץ הימני העלות של זה היא 4 וחישוב של האופרנד השמאלי עם רגיסטר 1 היא 2. בסוף חישוב פקודת ה-add היא 1, לכן התוצאה הסופית היא 7. והיא עדיפה.

<u>ייצור הקוד:</u>

המטרה היא לייצר את הקוד, לפי וקטור המחירים בשורש נראה כי מספר שורות הקוד המינימלי הוא 7 (לפי העלות המינימלית):

Load r0 C – get the value of C from the memory, now we have only one available register – r1
load r1 D
div r1 r1 E – get the value of E from the memory (costs 1), divide r1 (=D) / E and put it in r1
mul r0 r0 r1 – now we have the right operand of the + operator. (for the left operand we have only one available register – r1).

load r1 a
sub r1 r1 b

add r1(can be also r0) r1 r0 – the result of the addition in register r1 (or r0)

Store r1 – if we want to store the result in the memory we need one more command (and it generates 8 command – as we can see in the price vector of the root).

קומפילציה

חומר למבחן: אין בחירה!!!!

- כתיבת קוד ב-flex & bison – כנראה רק bison וגם דקדוק
- טבלת SLR(1) – צריך לדעת איך לבנות ולהשתמש בה.
- טבלת LL(1) – סיכוי גבוה שיהיה (כולל recursive descent parser).
- ייצור קוד ביניים בעזרת bison (תוויות סימבוליות, recursive descent parser, backpatching) – יכול להיות בעזרת bison לפי כללי גזירה נתונים. אולי עם recursive descent parser.
- יצור קוד מ-AST
- נושאים קטנים יותר:
- GC
- אלגוריתם תכנות דינאמי
- מספרי ershor
- linker – אם תהיה שאלה, יהיה סיכום.
- activation record (access link)

Garbage collection (GC)

בעיות עם שחרור זכרון ידני :

- כששוכחים לשחרר זכרון – memory leak
- ממשיכים להשתמש במצביע לזכרון שכבר שוחרר – dangling pointer.

- **Reference counter-** לכל אובייקט יש מונה הסופר את מס' ה- references לאובייקט (...c++,python). בכל פעולת השמה של המצביעים לאובייקט המונה יתעדכן בהתאם. כל פעולת השמה תגרור איתה הפחתת המונה של אובייקט אחד והגדלת המונה של אובייקט אחר, פעולה שלוקחת זמן (אומנם מאוד קטן, אבל בהיבטים מסויימים זה יכול להיות קריטי) ובנוסף המונה תופס עוד תא בזכרון לאותו האובייקט. אם יש אובייקט שיש לו תחתיו עץ מוצבעים (אובייקטים שהוא מצביע עליהם), ברגע שאותו אובייקט משוחרר , נגיד כשאין לו יותר מצביעים עליו (המונה שלו התאפס), אז צריך לעבור על כל התת עץ שלו ולהקטין בהתאם את המונה שלהם, במקרים מסויימים זה יכול לקחת יחסית הרבה זמן.
בעיה נוספת היא מעגל של הצבעות, אובייקט1 מצביע על אובייקט2 שמצביע על אובייקט3 שמצביע חזרה לאובייקט1, ועל אובייקט1 מצביע עוד אובייקט מבחוץ (הדרך היחידה להגיע למעגל הזה) אז כשננתק את ההצבעה החיצונית, המונה לא התאפס, ולכן יש זליגת זכרון כי נותר מעגל שאין דרך להגיע אליו, זהו אחד החסרונות הגדולים של השימוש במונה.

Mark and sweep

שיטת עבודה אחת של garbage collector. לכל אובייקט יש שדה (סיבית אחת) אשר מסמנת האם ניתן להגיע להאובייקט מהתוכנית או לא, אם הסיבית היא 1 אז ניתן להגיע אליו וה-garbage collector לא ישחרר אותו, אם היא 0 אז הוא יעשה לו sweep .

ה-GC סורק את האובייקט ומוציא את כל ה-references המאוחסנים בו.

Root set ב-java, האובייקט שממנו מתחילים את החיפוש של "ההצבעות", שכולל משתנים מקומיים של המתודות שפעילות עדיין ומשתנים סטטים – היות ולמשתנים סטטיים תמיד (כמעט) ניתן לגשת. ה-root set מיוצג כעץ וה-GC עובר על העץ הזה בעזרת BFS ומסמן את האובייקטים שניתן להגיע אליהם – שלב ה-mark. לאחר מכן שהוא סיים את הסריקה הוא עושה סריקה לכל ה-heap שמחזיק את המשתנים של התוכנית ועבור אותם האובייקטים שהסיבית שלהם היא 0 (כלומר אי אפשר לגשת אליהם) הוא מפנה אותם ועבור אלו שהסיבית שלהם 1, הוא הופך אותה ל0 עבור הסריקה הבאה – זה השלב של ה-sweep. בסריקה הבאה הוא שוב יסרוק את העץ ואם ניתן עדיין להגיע לאותו האובייקט שסומן בסיבית 0 בסבב הקודם, הסיבית שלו תשתנה ל1 שוב, וכך חוזר חלילה. הסריקה של ה-heap היא החסרון הגדול של השיטה.

קומפילציה

Baker – 4 רשימות של אובייקטים

- **Unscanned –** אובייקטים שגילינו שניתן להגיע אליהם אך טרם נסרקו.
- **Unreached –** לא ניתן להגיע אליהם ככל הידוע (בהתחלה כל ה-allocated objects ברשימה זו).
- **Free list**
- **Scanned**

היתרון של baker הוא שאין צורך לסרוק את כל ה-heap כדי לעשות sweep.

בסוף הסריקה של ה-root set כל מי שנשאר ברשימה של ה-unreached הוא אובייקט שלא ניתן להגיע אליו ולכן הוא עובר ל-free list.

Free = free U unreached.

לאחר מכן לסריקה הבאה מחליפים את הכתובת של הרשומה של ה-unreached לכתובת של ה-scanned וככה בעצם במקום לשנות את הסיבית של כל אובייקט, ה-GC ידע לסרוק את הרשימה של ה-scanned מהסבב הקודם וזאת ניתן לעשות ב-O(1) כיוון שזה רק שינוי כתובת.

mark and compact

לאחר הסריקה של ה-root set, את כל האובייקטים שהם לא זבל, הוא מקבץ אותם למקום כלשהו בזכרון (compact). כלומר קובעים לכל אובייקט כתובת חדשה ורושמים אותה בטבלה הממפה כתובות ישנות לכתובות חדשות, ולאחר מכן מזיזים את האובייקטים למקומם החדש, ההזזה נעשית תוך כדי סריקה של הזכרון מהכתובות הנמוכות לגבוהות.

Cheney copy collector

בשיטה הזו מנהלים טבלה שמחזיקה 2 מצביעים בעמודת ה-TO , האובייקטים שכתובים לפני המצביע unscanned הם אותם אובייטים שנסרקו. מה שנמצא בין unscanned ובין free הם אובייקטים שלא נסרקו וגם אובייקטים שצריך אולי לשחרר אותם בסבב הבא.
כשמוסיפים אובייקט שצריך לשחרר המצביע של free מקודם וכך בעצם אוטומטית אותו אובייקט מתווסף לסריקה של הסבב הבא.
כשמסיימים לסרוק אובייקט מזיזים את המצביע unscanned ככה שאותו אובייקט מתווסף לרשימה של ה-scanned. כשהמצביעים unscanned ו-free שווים זה אומר שהסריקה הסתיימה.

Basic block graph

קומפיילרים בונים מהקוד ביניים, גרף בלוקים ,כאשר כל בלוק מכיל קטע קוד ביניים אשר אין בתוכו – באמצע, קפיצות לתוויות חיצוניות, כלומר כל בלוק מתבצע בשלמותו, וקפיצה לתווית אחרת, או תנאי עם פיצול יהיה בסוף הבלוק. הקומפיילר בונה את הגרף הזה עבור אופטימיזציה – שיפור של קוד הביניים. את הגרף בונים בנפרד לכל מתודה.

ישנם כמה סוגי אופטימיזציה:

- אופטימזציה לוקאלית – עובדת על בלוק יחיד בגרף.
- אופטימיזציה גלובאלית – עובדת על כל גרף הבלוקים.

קומפילציה

Copy propogation - אופטימיזציה שבה הקומפיילר משנה משהו בקוד הביניים, וזה גורר שיפור נוסף שניתן לעשות.

available variables – משתנים זמינים, כלומר משתנה שמחזיק ערך כלשהו כך שבמקום לעשות חישוב חוזר של אותו הערך, ניתו להחליף את החישוב במשתנה הזמין. A=8+5, b = 8+5 => b = a.

Live variables – משתנה חי בנקודה מסויימת בתוכנית אם קיימת אפשרות שיהיה שימוש בערכו הנוכחי בהמשך התוכנית. אנליזה של משתנים חיים מתבצעת על בלוק יחיד (בד"כ מסוף הבלוק להתחלה). עוברים על הבלוק מהסוף ורואים באילו משתנים משתמשים לצורך חישוב או השמה לתוך משתנה אחר, כלומר עד לנקודה הנוכחית אנחנו צריכים את המשתנים (החיים). אם דורסים משתנה (עושים לתוכו השמה) אז עד לאותה השורה בקוד אותו המשתנה שלתוכו עושים השמה לא חי, כי הוא גם ככה נדרס בשורה הזאת, אבל לאחר השורה הזאת הוא הופך להיות שוב רלוונטי (לא בכל המקרים זה ככה). לאחר ביצוע האנליזה, עוברים מתחילת הבלוק לסופו, ורואים האם המשתנה שלתוכו עושים השמה, חי לאחר ההשמה, אם לא אפשר למחוק את השורה של ההשמה, כלומר מוחקים קוד מת.

ניתן להסיק מזה שכמה משתנים חיים באותה נק' זמן, שאסור להקצות למשתנים האלה את אותו הרגיסטר, כלומר כל אחד אמור להיות ברגיסטר משלו, היות וניתן לעשות מיחזור רגיסטרים עבור משתנים חיים.

גישה של קומפיילרים להקצאות רגיסטרים עבור שפת אסמבלי – chaitin's algorithm

לאחזר האנליזה של המשתנים החיים, עוברים על הקוד מהתחלה, ועבור כל נק' זמן שבה יש כמה משתנים חיים ביחד, מציירים גרף מלא עבורם. לאחר שציירנו את הגרף עבור כל המצבים, צובעים את הצמתים כך שלא יהיה אותו הצבע בקודקודים סמוכים. כמות הצבעים היא לפי כמות הרגיסטרים הזמינים. נגיד שיש 4 רגיסטרים, אז יש 4 צבעים שונים. צביעת הגרף תתבצע ברקורסיה, נוציא בכל צעד קודקוד אשר יש לו לכל היותר 3 שכנים, זאת כיוון שכשנוציא את כל הקודקודים, נצבע ברקורסיה, ולכן אם נחזיר קודקוד שיש לו 4 שכנים, והם כבר צבועים, לא נוכל לצבוע את הקודקוד הנוכחי שהחזרנו. נמשיך להוציא קודקודים ולצבוע אותם (נגיד לפי סדר הצבעים). במצב שבו יש קודקוד עם 4 שכנים ואין ברירה אלא להוציא קודקוד כזה, כשנחזיר אותו הערך שלו ישמר בזכרון – spilled. ישנם מצבים שבהם בהחזרת הקודקודים למרות שלקודקוד מסויים יש הרבה שכנים (כמספר הרגיסטרים או יותר), הצביעה תתבצע כך שלא יהיו 2 שכנים בעלי אותו צבע.

JVM

הקומפיילר של ג'אווה יוצר מקבצי java. קבצים עם סיומת class שהם כתובים ב-byte-code. הקבצים האלו נכנסים ל-JVM. בנוסף קיים קומפיילר – JIT – just in time Compiler, שהוא חלק מה-JVM ומייצר את הקוד בשפת מכונה, הוא קומפיילר חכם שעוקב אחרי הנעשה בקוד.