

| | | | | | | | |
|---|---|---|---|--|---|----------------------------------|--|
| לאחר הפעלה של אלגוריתם, [Gradient Descent] יתקבלו ערכי משקלים שעבורם תתקבל [התוצאה הנמוכה ביותר] מפונקציית השגיאה (לכאורה [מינימום גלובלי]). התוצאה תלויה בגודל הצעד. ככל שהצעד [יותר קטן], כך ה[מינימום] שיתקבל יהיה יותר קרוב ל[מינימום גלובלי] ופונקציית השגיאה תיתן ערך [יותר קטן] אך הזמן לחישוב יהיה ארוך יותר מכיוון שיהיו יותר (epochs). פתרון ה, [Normal Equation] - ימצא משקלים שנותנים שגיאה שערכה שווה בדיוק ל[מינימום גלובלי]. | כמה פתרונות קיימים לבעיית רגרסיה לינארית כאשר ב-D יש 3 דוגמאות (בלתי תלויות לינארית) ממימד 2? שימו לב שמספר המשקלים גדול באחד מהמימד, מכיוון שצריך להוסיף גם את ה-intercept. | | | | | | |
| התשובה הנכונה היא: ה[מינימום] שמתקבל כתוצאה מאלגוריתם Gradient Descent הוא בקירוב ה[גלובלי], מכיוון שאנו משתמשים ברגרסיה לינארית (או לוגיסטית) ויש לנו [בדיוק] נקודת [מינימום] אחת (פונקציית השגיאה שלנו הינה [ריבועית]). [אם נרץ את המודל על רשת נוירונים שבה יש נקודות [מינימום] רבות, אנו עלולים לקבל [מינימום] [מקומי] שרירותי כתלות בערכי המשקלים הרנדומליים ההתחלתיים]. גודל הצעד משפיע על יכולת האלגוריתם להתקרב לנקודת ה[מינימום]; ככל שהצעד יהיה גדול יותר, ההתכנסות תהיה יותר [מהירה] אך השיפור בשגיאה יפסיק רחוק יותר מנקודת ה[מינימום]. | כמה פתרונות קיימים לבעיית רגרסיה לינארית כאשר ב-D יש 4 דוגמאות (בלתי תלויות לינארית) ממימד 2? שימו לב שמספר המשקלים גדול באחד מהמימד, מכיוון שצריך להוסיף גם את ה-intercept. | | | | | | |
| מהי סיבוכיות הזמן של אלגוריתם Normal Equation ? השתמשו באחד או יותר מהמשתנים הבאים: - D - אוסף דוגמאות האימון. - d - מספר המשתנים (הפיצ'רים) המקסימלי בדוגמת אימון אחת - H - אוסף ההיפותוזות (המשוואות שחוזות את תווי דוגמת האימון). | ברצוננו לסווג תמונה ל- 3 קטגוריות: A, B ו- C. הקטגוריות הן Mutual exclusive. עושים זאת בעזרת רגרסיה לוגיסטית One vs Rest ו- Cross Entropy. איזה וקטור (Targets) t יהיה שימושי עבור התמונות המסווגות? התשובה הנכונה t: הוא וקטור בוליאני [3] shape בקידוד One-Hot | | | | | | |
| <table><tr><td>הכפלה של X^T ב- X: $O(d^2 D)$</td><td>הכפלה של X^T ב- t: $O(d D)$</td><td>מצאת מטריצה הופכית ל- $X^T X$: $O(d^3)$</td></tr><tr><td>הכפלה של $(X^T X)^{-1}$ ב- $X^T t$: $O(d^2)$</td><td>סה"כ: $O(d^2 D + d D + d^3 + d^2)$</td><td>לאחר צמצום: $O(d^2 D + d^3)$</td></tr></table> | הכפלה של X^T ב- X : $O(d^2 D)$ | הכפלה של X^T ב- t : $O(d D)$ | מצאת מטריצה הופכית ל- $X^T X$: $O(d^3)$ | הכפלה של $(X^T X)^{-1}$ ב- $X^T t$: $O(d^2)$ | סה"כ: $O(d^2 D + d D + d^3 + d^2)$ | לאחר צמצום: $O(d^2 D + d^3)$ | |
| הכפלה של X^T ב- X : $O(d^2 D)$ | הכפלה של X^T ב- t : $O(d D)$ | מצאת מטריצה הופכית ל- $X^T X$: $O(d^3)$ | | | | | |
| הכפלה של $(X^T X)^{-1}$ ב- $X^T t$: $O(d^2)$ | סה"כ: $O(d^2 D + d D + d^3 + d^2)$ | לאחר צמצום: $O(d^2 D + d^3)$ | | | | | |
| מהי סיבוכיות הזמן של אלגוריתם Gradient Descent? השתמשו באחד או יותר מהמשתנים הבאים: - D - אוסף דוגמאות האימון. - d - מספר המשתנים (הפיצ'רים) המקסימלי בדוגמת אימון אחת. - H - אוסף ההיפותוזות (המשוואות שחוזות את תווי דוגמת האימון). - e - מספר ה epochs - המקסימלי. | נסתכל על מרחב קלט 2D: פולינום מדרגה 1: 2 קלטים (ועוד ביאס) x_1, x_2 פולינום מדרגה 2: 5 קלטים (ועוד ביאס) $x_1, x_2, x_1x_2, x_1^2, x_2^2$ פולינום מדרגה 3: 9 קלטים $x_1, x_2, x_1x_2, x_1^2, x_2^2, x_1^2x_2, x_1x_2^2, x_1^3, x_2^3$ מה היה קורה אם מרחב הקלט המקורי הוא 3D והפולינום הדרוש הוא מדרגה 2? $x_1, x_2, x_3, x_1x_2, x_1x_3, x_2x_3, x_1^2, x_2^2, x_3^2,$ | | | | | | |
| | [8] בהינתן מסווג של naive Bayes בעל 3 קלטים בוליאנים X1,X2,X3 ופלט בוליאני Y. a. מהו מספר הפרמטרים (המינימלי) שהמסווג צריך לשערך לצורך למידה? רשום אותם. $p(+), p(x1=1 +), p(x2=1,+), p(x3=1 +)$ $p(x1=1 -), p(x2=1 -), p(x3=1 -)$ היתר ניתנים לחישוב למשל $p(x_i=0 +) = 1 - p(x_i=1 +)$, $p(-) = 1 - p(+)$, סה"כ 7 | | | | | | |
| | כמה פתרונות קיימים לבעיית רגרסיה לינארית כאשר ב D -יש 2 דוגמאות (בלתי תלויות לינארית) ממימד 2? שימו לב שמספר המשקלים גדול באחד מהמימד, מכיוון שצריך להוסיף גם את ה-intercept. תשובה: בהסתכלות גרפית מדובר על גרף של 3D (כאשר יש 2 דוגמאות ממימד 2, אז יש 2 פיצ'רים; צירים X ו-Y ויש את ערך ה-target; ציר ה-Z). כאשר נשים 2 נקודות (2 דוגמאות) על הגרף, יש אין סוף משטחים שניתן להעביר דרך 2 הנקודות הללו ושיתנו ערך שגיאה מינימלי. התשובה הנכונה: אין סוף פתרונות | | | | | | |

שערוך ההסתברות:

| | | |
|--------------------|---|---|
| $P(cancer)$ | = | 0.008 |
| $P(\neg cancer)$ | = | 0.992 |
| $P(+ cancer)$ | = | 0.98 |
| $P(- cancer)$ | = | 0.02, False neg 2% |
| $P(+ \neg cancer)$ | = | 0.03 False pos 3% |
| $P(- \neg cancer)$ | = | 0.97 |
| $P(cancer +)$ | = | $P(+ cancer)P(cancer)/P(+)=0.98*0.008/p(+)=0.00784 / P(+)$ |
| $P(\neg cancer +)$ | = | $P(+ \neg cancer)P(\neg cancer)/P(+)=0.03*0.992/p(+)=0.0298 / P(+)$ |

Joint probabilities: $P(+,cancer)=p(+|cancer)p(cancer) \approx 0.98*0.008=0.00784$
 $P(+, \neg cancer) = p(+|\neg cancer)p(\neg cancer) \approx 0.03*0.992=0.0298$

• מה ההסתברות של $P(cancer|+)$?

- $P(+)=P(cancer,+) + P(\neg cancer,+) \approx 0.00784+0.0298=0.03764$
- $P(cancer|+) \approx 0.00784/0.03764=0.21$
- $P(\neg cancer|+) \approx 0.0298/0.03764=0.79$

Naïve Bayes Classification Algorithm:

Naïve_Bayes_Classifier Training (D)

For each category $k=1...K$

- $P(k)=\text{estimate } p(y=k) \approx \frac{n_k}{n}$

• For each value v_j of each attribute x_j

- $P(v_j|k)=\text{estimate } p(x_j=v_j | y=k) \approx \frac{n_{v_j,k}}{n_k}$

Naïve_Bayes_Classifier Inference(x)

$$\text{predict} = \underset{k}{\text{argmax}} \{P(k) \prod_{j=1}^n P(v_j|k)\}$$

שלב ראשון: הערכת כל ההסתברויות הנחוצות:
 • ה priors של הקלסים וגם ההסתברויות של הקטגוריות של features בהנתן קטגוריה

שלב שני: קבלת קלט: $x=(v_1, v_2, \dots, v_n)$
 וחישוב $\underset{k}{\text{argmax}} p(x,k)$ של $p(x,k)$

את ה Priors ניתן לשערך מ D אם הוא מדגם טוב של כל האוכלוסיה
 אם המדגם איננו של כל האוכלוסיה, אולי ניתן לשערך ממקורות אחרים: ספרי לימוד, ידע של מומחים
 במקרים אשר בהם לא ניתן לשערך את ה priors, מניחים איזון בין הקטגוריות ומשתמשים ב Max-likelihood

כן, exhausted feature selection. סיבוכיות - 2^n

תשובה: CV

$$\text{minimize}_w \left\{ \sum_{i=1}^m \max[0, 1 - y_i h(x_i)] + \gamma \sum_{j=1}^n w_j^2 \right\}$$

Example: Classification using Bayes Rule

$$p(k|x) = \frac{p(k)p(x|k)}{P(x)} = \frac{p(k)p(x|k)}{\sum_i^K p(x|i)p(i)}$$

דוגמא: $X='fever'$ הינו סימפטום, וצריך לסווג: $k=1$ (notCorona), $k=2$ (Corona)

בהרבה מיקרים קל יותר להשיג סטטיסטיקה על

$P(corona|fever)$ מאשר על $p(fever|corona)$

מספיק לדעת את $p(fever|corona)$, את ה

prior של Corona ואת ה prior של fever

כדי לחשב $p(Corona|fever)$

נניח $p(fever)=0.0011$, $P(corona)=0.001$, $p(fever|corona)=0.7$

$$p(corona|fever)=0.001*0.7/0.0011$$

לחילופין, אם אין את הסטטיסטיקה על $p(fever)$ אולי

נוכל להשיג את $p(fever|notcorona)=0.0004$

$$P(corona|fever)=0.001*0.7/(p(fever|corona)p(corona)+p(fever|notcorona)p(notcorona))=0.001*0.7/(0.7*0.001+0.0004*0.999)$$

תרגיל ביאזיאני:

איבחון מחלה על פי סימפטום/בדיקה

MAP vs. ML :

מטופל נבדק במעבדה והבדיקה חוזרת חובית למחלת הסרטן.

האם תבחר לעשות לו ניתוח מורכב?

- **בדיקת מעבדה חובית תתקבל ב 98% מהמיקרים בהם ישנה המחלה (רגישות 0.98):**
 2% של false negative rate - חולים שקיבלו בדיקה שלילית
 98% של true positives rate - חולים שקיבלו בדיקה חובית

$$P(-|cancer) \approx 0.02$$

$$P(+|cancer) \approx 0.98$$

- **תוצאה שלילית נכונה תתקבל ב 97% מהמיקרים בהם המחלה איננה (ספציפיות 0.97):**

$$P(+|\neg cancer) \approx 0.03$$

$$P(-|\neg cancer) \approx 0.97$$

3% של false positives rate - בריאים עם בדיקה חובית

97% של true negative rate - בריאים עם בדיקה שלילית

$$P(cancer) \approx 0.008$$

$$P(\neg cancer) \approx 0.992$$

- **ידע מוקדם: 0.8% מהאוכלוסיה חולים במחלה**

האם הסיכוי של המטופל להיות חולה גדול מהסיכוי שלו להיות בריא?

מכיוון שהמספרים מבוססי מדגם, הם רק שערוכים של ההסתברויות

ל- y שתי קטגוריות: $cancer$, $\neg cancer$

x הוא תוצאת הבדיקה: מאפיין בוליאני + או -

סוג חולה או לא חולה על פי MAP וגם על פי ML.

מה מספר הפרמטרים המינימלי שהמסווג צריך לשערך מתוך D אם לא נשתמש בהנחה הנאיבית?

$p(x|+)$ ו $p(x|-)$ לכל אחד מ 7 קלטים שיכולים להינתן (את השמיני ניתן

לחשב). סה"כ $2^7=128$. את ה Priors ניתן לחשב.